

Clasificación del estado de madurez de paltas Hass

ResNet-50 frente a ViT-S/16 con presupuesto equiparado

Cristóbal Martínez ■ Avance, 28 de septiembre de 2026

14.710 fotografías, 478 frutas, índice de madurez de 5 niveles

El problema

Por qué importa acá y no solo en el paper

- Chile es uno de los mayores exportadores de palta Hass del mundo.
- La clasificación por madurez se hace hoy a ojo y al tacto, operario por operario, sin criterio homogéneo ni trazabilidad.
- Fruta verde en góndola: el consumidor la descarta. Fruta pasada en tránsito: pérdida total. Los dos errores cuestan.
- La tarea es **ordinal**, no categórica: $1 < 2 < 3 < 4 < 5$.
- Confundir un 1 con un 2 es un error de un día. Confundir un 1 con un 5 es mandar fruta podrida a la venta.

Índ.	Estado	Decisión
1	Verde	Dejar madurar
2	Iniciando	Lista en 2–3 días
3	Maduro I	Venta inmediata
4	Maduro II	Último día
5	Sobremaduro	Fuera de punto

La métrica tiene que castigar más los errores lejanos. La accuracy plana no lo hace: por eso usamos QWK.

Los datos

Hass Avocado Ripening Photographic Dataset, Mendeley, CC BY 4.0

Imágenes

14.710

Frutas


478

Clases

5

Grupos

3




Xavier, Rodrigues & Silva (2024), DOI 10.17632/3xd9n945v8.1. Etiquetado visual experto, sin acuerdo inter-evaluador reportado.

El riesgo que define el proyecto

Fuga de datos longitudinal

- La misma palta fue fotografiada a diario durante hasta 26 días.
- Dos fotos consecutivas de la fruta #173 son casi idénticas: misma piel, mismas manchas, misma forma.
- Un split aleatorio por imagen pondría el día 5 en train y el día 6 en test.
- El modelo reconocería la fruta, no el estado de madurez. La métrica sería alta y completamente falsa.
- Hay 6.871 pares de días consecutivos de la misma fruta.
- Partimos las 478 frutas, no las 14.710 imágenes.




Estratificado por grupo de almacenamiento, con un assert en el código que falla si una fruta aparece en dos particiones.

Las dos redes, en una imagen

La diferencia es CÓMO miran la foto

ResNet-50 · una lupa que recorre la fruta ViT-S/16 · un rompecabezas que conversa



- Va de a pedacitos y reutiliza el mismo detector en toda la foto (*convolución*).
- Buena para detalles: manchas, arrugas, tono.

- Parte la foto en 196 cuadraditos y los compara todos contra todos (*auto-atención*).
- Buena para relacionar zonas distantes.

Ninguna se programó desde cero: las dos vienen de timm, la biblioteca estándar de modelos de visión.

Por qué entrenan tan distinto

Todo se explica por lo que cada red ya sabe antes de empezar

ResNet-50 trae dos reglas de fábrica

- Lo que importa está **cerca**
- **No importa** en qué parte de la foto esté

Una mancha café es una mancha café, arriba o abajo de la fruta.

Eso no lo aprende: ya lo trae.

ViT-S/16 no trae ninguna

- Todos los cuadraditos le parecen **iguales**
- Ni siquiera sabe cuáles son **vecinos**

Tiene que deducir de los ejemplos hasta la noción de «al lado».

- El ViT necesita muchísimos más ejemplos.
- La ResNet arranca sabiendo mirar imágenes; el ViT tiene que descubrir primero *cómo* se mira una imagen, y recién después aprender de paltas.
- Por eso los dos parten desde ImageNet.
- Antes de ver una sola palta ya vieron 1,3 millones de fotos de cosas cotidianas. Ahí el ViT compensa: llega con el oficio aprendido.
- Y por eso el ViT es más delicado de entrenar.
- Entrenar es bajar un cerro a ciegas y el *learning rate* es el tamaño del paso. La ResNet aguanta pasos grandes; el ViT se cae.

Cómo hacemos que la comparación sea justa

Igualar tres cosas, no solo el tamaño

Eje igualado	ResNet-50	ViT-S/16 (DeiT-S)	Diferencia
Parámetros	23,52 M	21,67 M	7,9 %
GFLOPs @ 224 px	8,17	8,48	3,6 %
Pre-entrenamiento	ImageNet-1k	ImageNet-1k	ninguna

- Si una red es más grande y gana, no aprendimos nada: ganó por grande.
- Por eso igualamos el tamaño (parámetros), el trabajo que hace por foto (GFLOPs) y — lo que casi nadie iguala — **cuántas fotos vio antes**.
- El tercer punto es el que más distorsiona.
- El ViT que usa todo el mundo viene entrenado con 14 millones de fotos; la ResNet, con 1,3 millones. Comparándolos así estaríamos midiendo quién estudió más, no qué arquitectura es mejor.
- Usamos una versión del ViT llamada **DeiT-S**: es exactamente la misma red, pero entrenada con las mismas 1,3 millones de fotos que la ResNet. Ahí sí la comparación es limpia.

Como comparar dos atletas: sirve si entrenaron lo mismo y compiten en la misma categoría de peso.

Cómo las entrenamos

Todo igual para las dos, salvo lo que tiene que cambiar

Idéntico para ambas

- Las mismas fotos, en el mismo orden
- Las mismas deformaciones de las fotos
- La misma cantidad de vueltas al dataset
- El mismo criterio para elegir el mejor modelo
- El mismo criterio para cortar el entrenamiento

Distinto en el ViT

- **Pasos 3 veces más chicos.**
- Con pasos grandes el ViT se desestabiliza y deja de aprender.
- **Arranque más lento (*warmup*).**
- Las primeras vueltas van a media máquina para que no se rompa.

Un detalle que suele hacerse mal: en casi cualquier otra tarea conviene alterar mucho los colores de las fotos de entrenamiento, para que el modelo no dependa del color. Acá el color es la respuesta: si alteramos mucho el tono, una palta clase 2 se vuelve idéntica a una clase 4 pero con la etiqueta vieja. Le estaríamos enseñando mal. Por eso el color casi no se toca; girar y recortar la foto, en cambio, sí.

■ Igualar el learning rate «por justicia» no sería más justo: sería solo peor para el ViT.

01 Resultados preliminares

Baseline ResNet-50

23,52 M params, 8,17 GFLOPs, 10 min, mejor época 11



QWK (principal)

0,936

Accuracy

74,6 %

Acc. ± 1 clase

99,2 %

MAE

0,262

Macro-F1

0,735

Grupo	n	Accuracy	MAE
T10 (10 °C)	1350	75,3 %	0,259
T20 (20 °C)	466	75,1 %	0,249
Tamb	446	71,8 %	0,285

- Los errores se concentran en clases adyacentes: 99,2 % cae en la clase correcta o en una vecina.
- MAE de 0,26 escalones sobre una escala de 5.
- Desempeño homogéneo entre grupos: el modelo **no** está explotando el sesgo «verde $\Rightarrow$ refrigerada».

■ Test: 2.262 imágenes de 72 frutas que ningún modelo vio.

Baseline ViT-S/16

21,67 M params, 8,48 GFLOPs, 5 min, mejor época 4

QWK (principal)

0,931

Accuracy

72,2 %

Acc. ± 1 clase

99,5 %

MAE

0,282

Macro-F1

0,711

Grupo	n	Accuracy	MAE
T10 (10 °C)	1350	73,9 %	0,267
T20 (20 °C)	466	68,7 %	0,318
Tamb	446	71,1 %	0,291

- Los errores se concentran en clases adyacentes: 99,5 % cae en la clase correcta o en una vecina.
- MAE de 0,28 escalones sobre una escala de 5.
- Desempeño homogéneo entre grupos: el modelo **no** está explotando el sesgo «verde $\Rightarrow$ refrigerada».

■ Test: 2.262 imágenes de 72 frutas que ningún modelo vio.


ResNet-50 frente a ViT-S/16

Intervalos por bootstrap agrupado por fruta, no por imagen

Modelo	Params	GFLOPs	QWK	Accuracy	Macro-F1	MAE	Acc. ± 1
ResNet-50	23,5 M	8,2	0,936	74,6 %	0,735	0,262	99,2 %
ViT-S/16	21,7 M	8,5	0,931	72,2 %	0,711	0,282	99,5 %

- **ViT-S/16:** $\Delta QWK = -0,0042$, IC 95 % $[-0,0095, +0,0006]$, $p = 0,095 \rightarrow$ **NO significativa**
- Un oráculo que eligiera siempre el modelo correcto llegaría a 82,0 % de accuracy, frente a 74,6 % del mejor modelo individual: hay complementariedad que explotar.
- Ambos modelos fallan a la vez en solo 18,0 % de las imágenes.
- Las 2.262 imágenes de test vienen de solo 72 frutas: asumir independencia entre imágenes daría intervalos artificialmente angostos, por eso el bootstrap remuestra *frutas*.


Los errores se concentran en la diagonal vecina: el modelo confunde estados adyacentes, no extremos



La ResNet acierta la clase exacta más seguido; el ViT se equivoca por menos distancia. Sobre QWK, que pondera el error por distancia, empatan.

Curvas de entrenamiento

Misma receta, convergencia distinta



- ResNet-50 alcanza su mejor QWK de validación en la época 11; ViT-S/16 en la 4.
- Tiempo de entrenamiento: 10 min frente a 5 min en una RTX 4070 Laptop de 8 GB. El ViT converge al doble de velocidad.

Riesgos identificados y mitigación

Concretos de este dataset, no genéricos

Riesgo	Por qué es real acá	Mitigación
Fuga longitudinal	6.871 pares de días consecutivos de la misma fruta	Split por fruta + assert automático
Domain gap lab. → terreno	Fondo blanco, fruta centrada, luz difusa controlada	Declarado en la data card; recolectar fotos de celular
Color = señal, no ruido	Un ColorJitter estándar vuelve una clase 2 en una clase 4	Jitter suave: hue 0,02 en vez de 0,1
Sesgo T10 ⇒ clase 1	T10 aporta 60 % de las imágenes con 40 % de las frutas	Pesos de clase + métricas desglosadas por grupo
Etiquetas subjetivas	Sin acuerdo inter-evaluador: techo humano desconocido	QWK y MAE en vez de accuracy; no perseguir 100 %
Ventaja oculta de pre-entren.	Los pesos ViT habituales vienen de ImageNet-21k	DeiT-S: ambos modelos solo ImageNet-1k

El domain gap es el riesgo que decide si esto sirve en un packing o solo en un paper.

Qué viene para el entregable final

Lo que falta para noviembre

- **Ablación sin pre-entrenamiento.**
- Los mismos dos modelos entrenados desde cero. Es la evidencia empírica propia de por qué ResNet y ViT difieren: el transformer no tiene sesgo inductivo de localidad y tiene que aprenderlo de los datos.
- **Dos modelos híbridos.**
- Fusión tardía de los dos backbones ya afinados, y el ViT-Hybrid R26+S/32 del paper original de ViT.
- **Interpretabilidad comparada.**
- Grad-CAM sobre la ResNet y attention rollout sobre el ViT, en los casos donde los dos modelos discrepan.
- **Demo funcional en Gradio y decisión explícita de velocidad frente a precisión.**

Repositorio: github.com/cmartinez1524/clasificacion-de-paltas