

Clasificación del estado de madurez de paltas Hass

ResNet-50 frente a ViT-S/16 con presupuesto equiparado

Cristóbal Martínez ■ Avance, 28 de septiembre de 2026

14.710 fotografías, 478 frutas, índice de madurez de 5 niveles

El problema

Por qué importa acá y no solo en el paper

- Chile es uno de los mayores exportadores de palta Hass del mundo.
- La clasificación por madurez se hace hoy a ojo y al tacto, operario por operario, sin criterio homogéneo ni trazabilidad.
- Fruta verde en góndola: el consumidor la descarta. Fruta pasada en tránsito: pérdida total. Los dos errores cuestan.
- La tarea es **ordinal**, no categórica: $1 < 2 < 3 < 4 < 5$.
- Confundir un 1 con un 2 es un error de un día. Confundir un 1 con un 5 es mandar fruta podrida a la venta.

Índ.	Estado	Decisión
1	Verde	Dejar madurar
2	Iniciando	Lista en 2–3 días
3	Maduro I	Venta inmediata
4	Maduro II	Último día
5	Sobremaduro	Fuera de punto

La métrica tiene que castigar más los errores lejanos. La accuracy plana no lo hace: por eso usamos QWK.

Los datos

Hass Avocado Ripening Photographic Dataset, Mendeley, CC BY 4.0

Imágenes

14.710

Frutas


478

Clases

5

Grupos

3




Xavier, Rodrigues & Silva (2024), DOI 10.17632/3xd9n945v8.1. Etiquetado visual experto, sin acuerdo inter-evaluador reportado.

El riesgo que define el proyecto

Fuga de datos longitudinal

- La misma palta fue fotografiada a diario durante hasta 26 días.
- Dos fotos consecutivas de la fruta #173 son casi idénticas: misma piel, mismas manchas, misma forma.
- Un split aleatorio por imagen pondría el día 5 en train y el día 6 en test.
- El modelo reconocería la fruta, no el estado de madurez. La métrica sería alta y completamente falsa.
- Hay 6.871 pares de días consecutivos de la misma fruta.
- Partimos las 478 frutas, no las 14.710 imágenes.



Estratificado por grupo de almacenamiento, con un assert en el código que falla si una fruta aparece en dos particiones.

Las redes que comparamos

Qué es cada una y qué asume

ResNet-50 *(convolucional, 2015)*

- Filtros pequeños que se deslizan por toda la imagen, apilados en 50 capas con conexiones residuales.
- **Trae un supuesto incorporado: localidad y equivarianza a la traslación.**
- Una mancha café significa lo mismo esté donde esté sobre la fruta. Eso *no hay que aprenderlo*: está en la arquitectura.

```
timm: resnet50.a1_in1k
```

ViT-S/16 *(transformer, 2020)*

- Corta la imagen de 224×224 en 196 parches de 16×16 y los procesa con auto-atención.
- Cada parche mira a todos los demás desde la primera capa; un token CLS resume la imagen.
- **No asume nada sobre estructura espacial.**
- Tiene que aprender de los datos lo que la convolución trae gratis.

```
timm: deit_small_patch16_224.fb_in1k
```

■ Ninguna se escribió desde cero: usamos `timm`, la biblioteca estándar de modelos de visión pre-entrenados.

Diseño de la comparación

Tres ejes igualados a la vez, no solo los parámetros

Eje igualado	ResNet-50	ViT-S/16 (DeiT-S)	Diferencia
Parámetros	23,52 M	21,67 M	7,9 %
GFLOPs @ 224 px	8,17	8,48	3,6 %
Pre-entrenamiento	ImageNet-1k	ImageNet-1k	ninguna

- El tercer eje es el que casi nadie iguala, y el que más distorsiona.
- Los pesos ViT-S más usados de timm (`vit_small_patch16_224.augreg_in21k_ft_in1k`) vienen de **ImageNet-21k**: catorce veces más datos que los de la ResNet. Con esos pesos la comparación mediría el tamaño del corpus, no la arquitectura.
- Por eso usamos **DeiT-S**: exactamente la arquitectura ViT-S/16, pero entrenada solo en ImageNet-1k, frente a `resnet50.a1_in1k`.

Comparar «una ResNet» contra «un ViT» sin igualar el presupuesto no dice nada: cualquier diferencia se explicaría por el tamaño.

La receta de entrenamiento

Idéntica para ambas redes, salvo lo que tiene que cambiar

Igual para las dos

- AdamW, schedule coseno con warmup
- AMP fp16 (casi duplica la velocidad en la 4070)
- Label smoothing 0,05
- Pesos de clase inversos a la frecuencia
- Recorte de gradiente a 1,0
- Mismas aumentaciones y mismos datos
- Checkpoint elegido por **QWK de validación**, no por accuracy
- Early stopping a las 5 épocas sin mejora

Aumentaciones de color deliberadamente suaves (hue=0.02 en vez de 0.1): acá el color es la etiqueta, y un ColorJitter estándar convertiría una clase 2 en una clase 4 sin cambiarle la etiqueta. Las geométricas sí son agresivas: recorte 0,65–1,0, volteo, rotación $\pm 20^\circ$.

Distinto en el ViT, y por qué

- **Learning rate** 3× menor (1e-4 vs 3e-4).
- Los transformers divergen con los LR que una ResNet con BatchNorm tolera sin problema.
- **Warmup más largo** (2 épocas vs 1).
- Sin warmup, la atención colapsa en las primeras épocas.
- **drop_path** = 0,1.
- *Stochastic depth*, el regularizador estándar de los ViT.

■ Igualar el learning rate «por justicia» no sería más justo: sería solo peor para el ViT.

01 Resultados preliminares

Baseline ResNet-50

23,52 M params, 8,17 GFLOPs, 10 min, mejor época 11



QWK (principal)

0,936

Accuracy

74,6 %

Acc. ± 1 clase

99,2 %

MAE

0,262

Macro-F1

0,735

Grupo	n	Accuracy	MAE
T10 (10 °C)	1350	75,3 %	0,259
T20 (20 °C)	466	75,1 %	0,249
Tamb	446	71,8 %	0,285

- Los errores se concentran en clases adyacentes: 99,2 % cae en la clase correcta o en una vecina.
- MAE de 0,26 escalones sobre una escala de 5.
- Desempeño homogéneo entre grupos: el modelo **no** está explotando el sesgo «verde $\Rightarrow$ refrigerada».

■ Test: 2.262 imágenes de 72 frutas que ningún modelo vio.

Baseline ViT-S/16

21,67 M params, 8,48 GFLOPs, 5 min, mejor época 4

QWK (principal)

0,931

Accuracy

72,2 %

Acc. ± 1 clase

99,5 %

MAE

0,282

Macro-F1

0,711

Grupo	n	Accuracy	MAE
T10 (10 °C)	1350	73,9 %	0,267
T20 (20 °C)	466	68,7 %	0,318
Tamb	446	71,1 %	0,291

- Los errores se concentran en clases adyacentes: 99,5 % cae en la clase correcta o en una vecina.
- MAE de 0,28 escalones sobre una escala de 5.
- Desempeño homogéneo entre grupos: el modelo **no** está explotando el sesgo «verde $\Rightarrow$ refrigerada».

Test: 2.262 imágenes de 72 frutas que ningún modelo vio.


ResNet-50 frente a ViT-S/16

Intervalos por bootstrap agrupado por fruta, no por imagen

Modelo	Params	GFLOPs	QWK	Accuracy	Macro-F1	MAE	Acc. ± 1
ResNet-50	23,5 M	8,2	0,936	74,6 %	0,735	0,262	99,2 %
ViT-S/16	21,7 M	8,5	0,931	72,2 %	0,711	0,282	99,5 %

- **ViT-S/16:** $\Delta QWK = -0,0042$, IC 95 % $[-0,0095, +0,0006]$, $p = 0,095 \rightarrow$ **NO significativa**
- Un oráculo que eligiera siempre el modelo correcto llegaría a 82,0 % de accuracy, frente a 74,6 % del mejor modelo individual: hay complementariedad que explotar.
- Ambos modelos fallan a la vez en solo 18,0 % de las imágenes.
- Las 2.262 imágenes de test vienen de solo 72 frutas: asumir independencia entre imágenes daría intervalos artificialmente angostos, por eso el bootstrap remuestra *frutas*.


Los errores se concentran en la diagonal vecina: el modelo confunde estados adyacentes, no extremos



La ResNet acierta la clase exacta más seguido; el ViT se equivoca por menos distancia. Sobre QWK, que pondera el error por distancia, empatan.

Curvas de entrenamiento

Misma receta, convergencia distinta



- ResNet-50 alcanza su mejor QWK de validación en la época 11; ViT-S/16 en la 4.
- Tiempo de entrenamiento: 10 min frente a 5 min en una RTX 4070 Laptop de 8 GB. El ViT converge al doble de velocidad.

Riesgos identificados y mitigación

Concretos de este dataset, no genéricos

Riesgo	Por qué es real acá	Mitigación
Fuga longitudinal	6.871 pares de días consecutivos de la misma fruta	Split por fruta + assert automático
Domain gap lab. → terreno	Fondo blanco, fruta centrada, luz difusa controlada	Declarado en la data card; recolectar fotos de celular
Color = señal, no ruido	Un ColorJitter estándar vuelve una clase 2 en una clase 4	Jitter suave: hue 0,02 en vez de 0,1
Sesgo T10 ⇒ clase 1	T10 aporta 60 % de las imágenes con 40 % de las frutas	Pesos de clase + métricas desglosadas por grupo
Etiquetas subjetivas	Sin acuerdo inter-evaluador: techo humano desconocido	QWK y MAE en vez de accuracy; no perseguir 100 %
Ventaja oculta de pre-entren.	Los pesos ViT habituales vienen de ImageNet-21k	DeiT-S: ambos modelos solo ImageNet-1k

El domain gap es el riesgo que decide si esto sirve en un packing o solo en un paper.

Qué viene para el entregable final

Lo que falta para noviembre

- **Ablación sin pre-entrenamiento.**
- Los mismos dos modelos entrenados desde cero. Es la evidencia empírica propia de por qué ResNet y ViT difieren: el transformer no tiene sesgo inductivo de localidad y tiene que aprenderlo de los datos.
- **Dos modelos híbridos.**
- Fusión tardía de los dos backbones ya afinados, y el ViT-Hybrid R26+S/32 del paper original de ViT.
- **Interpretabilidad comparada.**
- Grad-CAM sobre la ResNet y attention rollout sobre el ViT, en los casos donde los dos modelos discrepan.
- **Demo funcional en Gradio y decisión explícita de velocidad frente a precisión.**

Repositorio: github.com/cmartinez1524/clasificacion-de-paltas