

Clasificación del estado de madurez de paltas Hass

ResNet-50 frente a ViT-S/16 con presupuesto equiparado

Cristóbal Martínez ■ Avance, 28 de septiembre de 2026

14.710 fotografías, 478 frutas, índice de madurez de 5 niveles

El problema

Por qué importa acá y no solo en el paper

- Chile es uno de los mayores exportadores de palta Hass del mundo.
- La clasificación por madurez se hace hoy a ojo y al tacto, operario por operario, sin criterio homogéneo ni trazabilidad.
- Fruta verde en góndola: el consumidor la descarta. Fruta pasada en tránsito: pérdida total. Los dos errores cuestan.
- La tarea es **ordinal**, no categórica: $1 < 2 < 3 < 4 < 5$.
- Confundir un 1 con un 2 es un error de un día. Confundir un 1 con un 5 es mandar fruta podrida a la venta.

Índ.	Estado	Decisión
1	Verde	Dejar madurar
2	Iniciando	Lista en 2–3 días
3	Maduro I	Venta inmediata
4	Maduro II	Último día
5	Sobremaduro	Fuera de punto

La métrica tiene que castigar más los errores lejanos. La accuracy plana no lo hace: por eso usamos QWK.

Los datos

Hass Avocado Ripening Photographic Dataset, Mendeley, CC BY 4.0

Imágenes

14.710

Frutas


478

Clases

5

Grupos

3




Xavier, Rodrigues & Silva (2024), DOI 10.17632/3xd9n945v8.1. Etiquetado visual experto, sin acuerdo inter-evaluador reportado.

El riesgo de que la IA haga trampa

El error que habría inflado todos los resultados

- A cada palta le sacaron una foto por día, hasta 26 días seguidos.
- La foto del día 5 y la del día 6 de la misma palta son casi idénticas: misma piel, mismas manchas, misma forma.
- Si repartimos las fotos al azar, la trampa es inevitable.
- El día 5 queda en el material de estudio y el día 6 en la prueba. El modelo *reconoce esa palta* en vez de juzgar su madurez, como un alumno que vio las respuestas antes del examen.
- El resultado saldría altísimo y sería completamente falso.
- Por eso repartimos las 478 paltas, no las 14.710 fotos.
- Todas las fotos de una misma palta van juntas: o están en el estudio, o están en la prueba. Nunca en las dos.





El código tiene un chequeo automático que falla si alguna palta llegara a aparecer en los dos lados.

Las dos redes, en una imagen

La diferencia es CÓMO miran la foto

ResNet-50 · una lupa que recorre la fruta ViT-S/16 · un rompecabezas que conversa



- Va de a pedacitos y reutiliza el mismo detector en toda la foto (*convolución*).
- Buena para detalles: manchas, arrugas, tono.

- Parte la foto en 196 cuadraditos y los compara todos contra todos (*auto-atención*).
- Buena para relacionar zonas distantes.

Ninguna se programó desde cero: las dos vienen de timm, la biblioteca estándar de modelos de visión.

Por qué entrenan tan distinto

Todo se explica por lo que cada red ya sabe antes de empezar

ResNet-50 trae dos reglas de fábrica

- Lo que importa está **cerca**
- **No importa** en qué parte de la foto esté

Una mancha café es una mancha café, arriba o abajo de la fruta.

Eso no lo aprende: ya lo trae.

ViT-S/16 no trae ninguna

- Todos los cuadraditos le parecen **iguales**
- Ni siquiera sabe cuáles son **vecinos**

Tiene que deducir de los ejemplos hasta la noción de «al lado».

- El ViT necesita muchísimos más ejemplos.
- La ResNet arranca sabiendo mirar imágenes; el ViT tiene que descubrir primero *cómo* se mira una imagen, y recién después aprender de paltas.
- Por eso los dos parten desde ImageNet.
- Antes de ver una sola palta ya vieron 1,3 millones de fotos de cosas cotidianas. Ahí el ViT compensa: llega con el oficio aprendido.
- Y por eso el ViT es más delicado de entrenar.
- Entrenar es bajar un cerro a ciegas y el *learning rate* es el tamaño del paso. La ResNet aguanta pasos grandes; el ViT se cae.

Cómo hacemos que la comparación sea justa

Igualar tres cosas, no solo el tamaño

Qué igualamos	ResNet-50	ViT-S/16	Diferencia
Tamaño del «cerebro» (conexiones)	23,5 millones	21,7 millones	7,9 %
Esfuerzo que hace por foto	8,2 mil millones	8,5 mil millones	3,6 %
Fotos que vio antes de empezar	1,3 millones	1,3 millones	ninguna

- Si una red es más grande y gana, no aprendimos nada: ganó por grande.
- Por eso igualamos el tamaño (parámetros), el trabajo que hace por foto (GFLOPs) y — lo que casi nadie iguala — **cuántas fotos vio antes**.
- El tercer punto es el que más distorsiona.
- El ViT que usa todo el mundo viene entrenado con 14 millones de fotos; la ResNet, con 1,3 millones. Comparándolos así estaríamos midiendo quién estudió más, no qué arquitectura es mejor.
- Usamos una versión del ViT llamada **DeiT-S**: es exactamente la misma red, pero entrenada con las mismas 1,3 millones de fotos que la ResNet. Ahí sí la comparación es limpia.

Como comparar dos atletas: sirve si entrenaron lo mismo y compiten en la misma categoría de peso.

Cómo las entrenamos

Todo igual para las dos, salvo lo que tiene que cambiar

Idéntico para ambas

- Las mismas fotos, en el mismo orden
- Las mismas deformaciones de las fotos
- La misma cantidad de vueltas al dataset
- El mismo criterio para elegir el mejor modelo
- El mismo criterio para cortar el entrenamiento

Distinto en el ViT *Siguiendo con la imagen del cerro:*

- **Le pedimos pasos 3 veces más cortos.**
- Es el *learning rate*. Con pasos largos el ViT tropieza y deja de aprender.
- **Y que empiece a caminar más lento.**
- Es el *warmup*: las primeras vueltas van a media máquina hasta que agarra el ritmo.

Un detalle que suele hacerse mal: en casi cualquier otra tarea conviene alterar mucho los colores de las fotos de entrenamiento, para que el modelo no dependa del color. Acá el color es la respuesta: si alteramos mucho el tono, una palta clase 2 se vuelve idéntica a una clase 4 pero con la etiqueta vieja. Le estaríamos enseñando mal. Por eso el color casi no se toca; girar y recortar la foto, en cambio, sí.

■ Igualar el learning rate «por justicia» no sería más justo: sería solo peor para el ViT.

01 Resultados preliminares

Resultado: ResNet-50

Un cerebro de 23,5 millones de conexiones, 10 minutos de entrenamiento

Acierta, o se pasa por un solo escalón

99,2 %

Cuando se equivoca, se equivoca por

0,26 escalones

Acierta la clase exacta en el 74,6 % de las fotos ■ puntaje con castigo (QWK) 0,936 ■ Macro-F1 0,735

- **Casi nunca se equivoca feo.**
- En 99,2 % de las fotos dice la clase correcta o una vecina. Confundir una palta verde con una podrida no le pasó nunca.
- **Se equivoca por menos de medio escalón.**
- 0,26 en una escala de 5 niveles: del orden de medio día de maduración.
- **Anda igual de bien en las tres temperaturas.**
- No está haciendo trampa con el atajo «verde $\Rightarrow$ seguro venía del refrigerador».

Medido sobre 2.262 fotos de 72 paltas que el modelo nunca había visto.

Resultado: ViT-S/16

Un cerebro de 21,7 millones de conexiones, 5 minutos de entrenamiento

Acierta, o se pasa por un solo escalón

99,5 %

Cuando se equivoca, se equivoca por

0,28 escalones


Acierta la clase exacta en el 72,2 % de las fotos ■ puntaje con castigo (QWK) 0,931 ■ Macro-F1 0,711

- **Casi nunca se equivoca feo.**
- En 99,5 % de las fotos dice la clase correcta o una vecina. Confundir una palta verde con una podrida no le pasó nunca.
- **Se equivoca por menos de medio escalón.**
- 0,28 en una escala de 5 niveles: del orden de medio día de maduración.
- **Anda igual de bien en las tres temperaturas.**
- No está haciendo trampa con el atajo «verde $\Rightarrow$ seguro venía del refrigerador».

Medido sobre 2.262 fotos de 72 paltas que el modelo nunca había visto.

ResNet-50 frente a ViT-S/16

El resultado central del avance




- Las dos rinden prácticamente igual.
- La ResNet acierta la clase exacta un poco más seguido. Pero cuando el ViT se equivoca, se equivoca por menos. Se compensa.
- Hicimos la prueba estadística formal y la diferencia entre ambas no es concluyente: para efectos prácticos, empatan.
- Pero no se equivocan en las mismas fotos.
- Fallan las dos a la vez en solo 18,0 % de los casos. Si alguien pudiera elegir siempre cuál de las dos tiene razón, acertaría 82,0 % en vez de 74,6 %.
- Eso es lo que van a intentar aprovechar los modelos híbridos.

Los números completos y las pruebas estadísticas están en el anexo.

Curvas de entrenamiento

Misma receta, convergencia distinta



- ResNet-50 alcanza su mejor QWK de validación en la época 11; ViT-S/16 en la 4.
- Tiempo de entrenamiento: 10 min frente a 5 min en una RTX 4070 Laptop de 8 GB. El ViT converge al doble de velocidad.

Riesgos identificados y mitigación

Concretos de este dataset, no genéricos

Riesgo	Por qué es real acá	Qué hicimos
Que la IA haga trampa	Hay 6.871 pares de fotos casi idénticas de la misma palta	Repartir paltas, no fotos, con chequeo automático
El choque con la vida real	Las fotos son de laboratorio: fondo blanco, luz perfecta, una fruta centrada. Un packing no se parece a eso	Lo declaramos como la limitación principal. Hay que salir a sacar fotos con celular
Alterar el color arruinaría el aprendizaje	El color es la respuesta: si lo cambiamos, la etiqueta queda mal	Alteramos el color lo mínimo; giramos y recortamos sin problema
Una temperatura domina los datos	El grupo refrigerado aporta el 60 % de las fotos y casi todas las paltas verdes	Compensamos en el entrenamiento y revisamos el resultado temperatura por temperatura
Nadie sabe cuál es el techo	Las etiquetas las puso una persona mirando; no hay una segunda opinión con qué contrastar	Usamos métricas que perdonan el error de un escalón y no perseguimos el 100 %
Darle ventaja a una de las dos redes	El ViT que se usa por defecto vino entrenado con 14 millones de fotos, no 1,3	Elegimos la versión del ViT que vio exactamente las mismas fotos que la ResNet

El choque con la vida real es el riesgo que decide si esto sirve en una planta empacadora o solo en un informe.

Qué viene para el entregable final

Lo que falta para noviembre

- **Desarmar el modelo para ver qué pieza importa.**
- Reentrenar las dos redes sin ImageNet, solo con las fotos de paltas. Debería mostrar que el ViT depende mucho más de haber estudiado antes.
- **Dos formas de juntar ambas redes en una.**
- Una que las hace opinar por separado y combina las dos respuestas; otra que las encadena, con la parte convolucional alimentando a la otra.
- **Ver dónde mira cada red.**
- Pintar sobre la foto las zonas que cada modelo usó para decidir, sobre todo en los casos donde las dos discrepan.
- **Una demo que funcione: subir una foto y ver la respuesta.**
- **Y una recomendación explícita: cuál llevaríamos a una planta real, pesando precisión contra costo.**

| Repositorio: github.com/cmartinez1524/clasificacion-de-paltas

A Anexo

Anexo: todas las métricas

Test: 2.262 imágenes de 72 frutas nunca vistas

Modelo	Params	GFLOPs	QWK	Accuracy	Macro-F1	MAE	Acc. ± 1	min
ResNet-50	23,5 M	8,2	0,9356	74,6 %	0,735	0,262	99,2 %	10
ViT-S/16	21,7 M	8,5	0,9313	72,2 %	0,711	0,282	99,5 %	5

- **QWK**: kappa de Cohen con pesos cuadráticos. Penaliza el error según el cuadrado de la distancia entre clases y corrige por acuerdo azaroso. Es la métrica con la que elegimos el mejor modelo.
- **MAE**: error medio en escalones del índice de madurez.
- **Acc. ± 1** : fracción de predicciones en la clase correcta o una adyacente.
- **Macro-F1**: F1 promediado por clase; controla que las clases minoritarias no queden abandonadas.

Anexo: pruebas estadísticas

Diferencias contra ResNet-50, con intervalo de confianza del 95 %

- ViT-S/16: $\Delta QWK = -0,0042$, IC 95 % $[-0,0095, +0,0006]$, $p = 0,095 \rightarrow$ **NO significativa**
- Los intervalos y los p -valores salen de un *bootstrap pareado agrupado por fruta*: las 2.262 imágenes vienen de solo 72 paltas, así que remuestrear imágenes daría intervalos artificialmente angostos. Se remuestran frutas, 2.000 réplicas.

Anexo: desglose por temperatura de almacenamiento

Sirve para detectar si el modelo se apoya en un atajo

Modelo	Grupo	n	Accuracy	MAE
ResNet-50	T10 (10 °C)	1350	75,3 %	0,259
ResNet-50	T20 (20 °C)	466	75,1 %	0,249
ResNet-50	Tamb	446	71,8 %	0,285
ViT-S/16	T10 (10 °C)	1350	73,9 %	0,267
ViT-S/16	T20 (20 °C)	466	68,7 %	0,318
ViT-S/16	Tamb	446	71,1 %	0,291

Desempeño parejo entre grupos: el modelo no está usando el atajo «verde $\Rightarrow$ refrigerada».