

Clasificación del estado de madurez de paltas Hass

ResNet-50, ViT-S/16 e híbridos con presupuesto equiparado

Cristóbal Martínez ■ Entrega final, 23 de noviembre de 2026

14.710 fotografías, 478 frutas, índice ordinal de 5 niveles

El problema

Por qué importa acá y no solo en el paper

- Chile es uno de los mayores exportadores de palta Hass del mundo.
- La clasificación por madurez se hace hoy a ojo y al tacto, operario por operario, sin criterio homogéneo ni trazabilidad.
- Fruta verde en góndola: el consumidor la descarta. Fruta pasada en tránsito: pérdida total. Los dos errores cuestan.
- La tarea es *ordinal*, no categórica: $1 < 2 < 3 < 4 < 5$.
- Confundir un 1 con un 2 es un error de un día. Confundir un 1 con un 5 es mandar fruta podrida a la venta.

Índ.	Estado	Decisión
1	Verde	Dejar madurar
2	Iniciando	Lista en 2–3 días
3	Maduro I	Venta inmediata
4	Maduro II	Último día
5	Sobremaduro	Fuera de punto

La métrica tiene que castigar más los errores lejanos. La accuracy plana no lo hace: por eso usamos QWK.

Datos y limitaciones

Hass Avocado Ripening Photographic Dataset, Mendeley, CC BY 4.0

Imágenes

14.710

Frutas

478

Train/val/test

334/72/72

Licencia

CC BY 4.0

- **Fuga longitudinal: resuelta.**
- 6.871 pares de días consecutivos de la misma fruta. Partimos frutas, no imágenes, con un assert que falla si una fruta aparece en dos particiones.
- **Domain gap laboratorio → terreno: no resuelta, declarada.**
- Fondo blanco uniforme, una sola fruta centrada, iluminación difusa controlada, distancia fija. Una foto de celular en una feria está fuera de distribución. Es la limitación que decide si esto sirve en un packing o solo en un paper.
- **Un lote, una cosecha, un cultivar, etiquetas subjetivas.**
- 478 frutas portuguesas de 2022, solo Hass, etiquetado visual sin acuerdo inter-evaluador reportado: no conocemos el techo humano de esta tarea.

Detalle completo en la data card ([entregables/final/data_card.md](#)).

Las redes que comparamos

Qué es cada una y qué asume

ResNet-50 (*convolucional, 2015*)

- Filtros pequeños que se deslizan por toda la imagen, apilados en 50 capas con conexiones residuales.
- **Trae un supuesto incorporado: localidad y equivarianza a la traslación.**
- Una mancha café significa lo mismo esté donde esté sobre la fruta. Eso *no hay que aprenderlo*: está en la arquitectura.

ViT-S/16 (*transformer, 2020*)

- Corta la imagen de 224×224 en 196 parches de 16×16 y los procesa con auto-atención.
- Cada parche mira a todos los demás desde la primera capa; un token CLS resume la imagen.
- **No asume nada sobre estructura espacial.**
- Tiene que aprender de los datos lo que la convolución trae gratis.

Híbrido 1: fusión tardía

- Los dos *backbones* corren en paralelo sobre la misma imagen; sus salidas se proyectan a 512 y se concatenan.
- Es el único modelo escrito a mano (`src/paltas/models.py`).

Híbrido 2: ViT-Hybrid R26+S/32

- El híbrido del paper original de ViT: un *stem* convolucional alimenta al transformer con su mapa de features.
- Híbrido *interno*, no una unión de dos redes.

■ Los dos híbridos NO son equiparables a los baselines ($2\times$ cómputo uno, ImageNet-21k el otro). Van como referencia.

Diseño de la comparación

Tres ejes igualados a la vez, no solo los parámetros

Eje igualado	ResNet-50	ViT-S/16 (DeiT-S)	Diferencia
Parámetros	23,52 M	21,67 M	7,9 %
GFLOPs @ 224 px	8,17	8,48	3,6 %
Pre-entrenamiento	ImageNet-1k	ImageNet-1k	ninguna

- El tercer eje es el que casi nadie iguala, y el que más distorsiona.
- Los pesos ViT-S más usados de timm (`vit_small_patch16_224.augreg_in21k_ft_in1k`) vienen de **ImageNet-21k**: catorce veces más datos que los de la ResNet. Con esos pesos la comparación mediría el tamaño del corpus, no la arquitectura.
- Por eso usamos **DeiT-S**: exactamente la arquitectura ViT-S/16, pero entrenada solo en ImageNet-1k, frente a `resnet50.a1_in1k`.

Comparar «una ResNet» contra «un ViT» sin igualar el presupuesto no dice nada: cualquier diferencia se explicaría por el tamaño.

La receta de entrenamiento

Idéntica para ambas redes, salvo lo que tiene que cambiar

Igual para las dos

- AdamW, schedule coseno con warmup
- AMP fp16 (casi duplica la velocidad en la 4070)
- Label smoothing 0,05
- Pesos de clase inversos a la frecuencia
- Recorte de gradiente a 1,0
- Mismas aumentaciones y mismos datos
- Checkpoint elegido por **QWK de validación**, no por accuracy
- Early stopping a las 5 épocas sin mejora

Aumentaciones de color deliberadamente suaves (hue=0.02 en vez de 0.1): acá el color es la etiqueta, y un ColorJitter estándar convertiría una clase 2 en una clase 4 sin cambiarle la etiqueta. Las geométricas sí son agresivas: recorte 0,65–1,0, volteo, rotación $\pm 20^\circ$.

Distinto en el ViT, y por qué

- **Learning rate** 3× menor (1e-4 vs 3e-4).
- Los transformers divergen con los LR que una ResNet con BatchNorm tolera sin problema.
- **Warmup más largo** (2 épocas vs 1).
- Sin warmup, la atención colapsa en las primeras épocas.
- **drop_path** = 0,1.
- *Stochastic depth*, el regularizador estándar de los ViT.

■ Igualar el learning rate «por justicia» no sería más justo: sería solo peor para el ViT.

01 Resultados

Tabla comparativa completa

Test: 2.262 imágenes de 72 frutas nunca vistas


Modelo	Params	GFLOPs	QWK	Accuracy	Macro-F1	MAE	Acc. ± 1	min
ResNet-50	23,5 M	8,2	0,936	74,6 %	0,735	0,262	99,2 %	10
ViT-S/16	21,7 M	8,5	0,931	72,2 %	0,711	0,282	99,5 %	5
ResNet-50 (scratch)	23,5 M	8,2	0,915	67,2 %	0,655	0,352	97,7 %	18
ViT-S/16 (scratch)	21,7 M	8,5	0,889	61,2 %	0,579	0,409	98,1 %	6
Híbrido: fusión tardía	46,4 M	16,7	0,941	76,7 %	0,760	0,238	99,5 %	4
ViT-Hybrid R26+S/32	36,0 M	6,9	0,941	76,2 %	0,752	0,242	99,6 %	15

Fila destacada: mejor QWK. El ViT-Hybrid R26 usa pesos de ImageNet-21k y más parámetros: es cota superior de referencia, no competidor equiparable.

ResNet frente a ViT: la comparación, no solo el número final

Todas las diferencias contra ResNet-50, bootstrap pareado agrupado por fruta

Los errores se concentran en la diagonal vecina: el modelo confunde estados adyacentes, no extremos



- **ViT-S/16**: $\Delta QWK = -0,0042$, IC 95 % $[-0,0095, +0,0006]$, $p = 0,095 \rightarrow$ **NO significativa**
- **ResNet-50 (scratch)**: $\Delta QWK = -0,0203$, IC 95 % $[-0,0283, -0,0123]$, $p = 0,000 \rightarrow$ **significativa**
- **ViT-S/16 (scratch)**: $\Delta QWK = -0,0465$, IC 95 % $[-0,0692, -0,0316]$, $p = 0,000 \rightarrow$ **significativa**
- **Híbrido: fusión tardía**: $\Delta QWK = +0,0055$, IC 95 % $[+0,0021, +0,0087]$, $p = 0,001 \rightarrow$ **significativa**
- **ViT-Hybrid R26+S/32**: $\Delta QWK = +0,0055$, IC 95 % $[+0,0005, +0,0104]$, $p = 0,031 \rightarrow$ **significativa**
- Todas las matrices son bandeadas: los errores de distancia ≥ 2 son casi inexistentes. Ningún modelo confunde una palta verde con una sobremadura.
- El cuello de botella son las clases intermedias (2, 3 y 4), donde la frontera es un corte continuo y las etiquetas son más subjetivas.

Por qué difieren (o no) ResNet y ViT

La ablación sin pre-entrenamiento es la evidencia

	ResNet-50	ViT-S/16	Lectura
QWK con ImageNet-1k	0,9356	0,9313	
QWK desde cero	0,9152	0,8891	
Δ QWK sin pre-entren.	-0,0203	-0,0422	el ViT pierde $2,1\times$ más
Δ accuracy sin pre-entren.	-7,4 pts	-11,0 pts	el ViT pierde $1,5\times$ más

- La ResNet trae el sesgo inductivo incorporado en la arquitectura.
- La convolución asume localidad y equivarianza a la traslación. Eso no hay que aprenderlo.
- El ViT tiene que aprender ese sesgo de los datos.
- La auto-atención es global desde la primera capa y no asume nada sobre estructura espacial. Con 10.208 imágenes de 334 frutas no alcanza para descubrirlo desde cero; con ImageNet-1k detrás, sí.
- Es un problema de textura local, no de forma global.
- El índice se lee en el color y las manchas de la cáscara, justo donde la convolución es fuerte. El campo receptivo global del ViT aporta poco.

■ Cada modelo comparado contra *su propia* versión pre-entrenada. Las cuatro caídas son significativas ($p < 0,0001$). El sesgo inductivo es un sustituto de datos.

Los híbridos

¿Suma combinar ambos enfoques?

Híbrido: fusión tardía

QWK 0,941


ViT-Hybrid R26+S/32

QWK 0,941

- Híbrido: fusión tardía: 46,4 M params, 16,7 GFLOPs, acc 76,7 %
- ViT-Hybrid R26+S/32: 36,0 M params, 6,9 GFLOPs, acc 76,2 %


- En su tabla de desacuerdo, fusión y ResNet fallan *a la vez* en 20,6 % de las imágenes: más que el 18,0 % del par ResNet/ViT. La fusión no elimina los casos difíciles, los absorbe.
- La fusión tardía cuesta el doble de cómputo por imagen.
- Dos backbones completos en el forward. La pregunta no es si mejora, sino si mejora lo suficiente para justificar $2\times$ de latencia.
- Alcanza su mejor checkpoint en la **época 2** (3,5 min) con los backbones congelados: las representaciones ya contenían la información, lo que faltaba era combinarlas.

Costo computacional frente a desempeño



Dónde mira cada arquitectura

Grad-CAM en la ResNet, attention rollout en el ViT



- No usamos la misma técnica en ambos a propósito: Grad-CAM necesita un mapa de activaciones con estructura espacial, y en un ViT ese mapa es una secuencia de tokens que produce resultados ruidosos.
- Attention rollout acumula las matrices de atención de todas las capas para estimar cuánto aporta cada parche al token CLS.
- La ResNet se activa sobre texturas locales: manchas, arrugas, zonas oscuras.
- El ViT reparte la atención sobre regiones más extensas.
- En varios casos de desacuerdo, el Grad-CAM de la ResNet se activa sobre el *fondo*, fuera de la fruta, y son justamente esos los casos en que se equivoca.

Decisión: velocidad frente a precisión

Qué modelo llevaríamos a una línea de empaque

Modelo	QWK	Δ QWK	GFLOPs	Costo rel.	Veredicto
ResNet-50	0,9356	—	8,17	1,00×	Referencia. La recomendación operativa.
ViT-S/16	0,9313	−0,0042	8,48	1,04×	Empata en QWK al mismo costo y converge 2× más rápido.
Híbrido: fusión tardía	0,9410	+0,0055	16,66	2,04×	Mejora real pero marginal por 2× de cómputo.
ViT-Hybrid R26+S/32	0,9411	+0,0055	6,88	0,84×	Mejor QWK y más barato, pero con ventaja de ImageNet-21k.

- El criterio no es el QWK máximo, es el QWK por unidad de cómputo.
- En un packing la inferencia corre sobre miles de frutas por hora, probablemente en un equipo sin GPU dedicada.
- Una diferencia de QWK que no es estadísticamente significativa no justifica duplicar el cómputo: si los intervalos se solapan, gana el modelo más barato.
- Con accuracy ± 1 clase por sobre el 99 %, el error residual está dentro del ruido de etiquetado humano. Optimizar más el modelo no es donde está el retorno; cerrar el domain gap sí.

Demo

Gradio, casos nuevos del conjunto de test

- **Selección de modelo, distribución de probabilidad sobre las 5 clases y recomendación operativa.**
- Muestra además el mapa de atención del modelo: la demo no es una caja negra.
- Reporta el índice esperado (promedio ponderado), más informativo que el `argmax` cuando el modelo duda entre estados adyacentes.
- Avisa explícitamente cuando la confianza es baja y conviene revisión humana.
- **Los ejemplos precargados salen solo del conjunto de test: son frutas que ningún modelo vio durante el entrenamiento.**
- Advierte en pantalla sobre el domain gap.

`python app/gradio_app.py → http://localhost:7860`

Conclusiones y trabajo futuro

Qué aprendimos y qué sigue

- **Con presupuesto y pre-entrenamiento equiparados, las dos arquitecturas resuelven esta tarea a un nivel comparable.**
- La diferencia relevante no está entre CNN y transformer, sino entre tener o no tener pre-entrenamiento: ahí sí se separan, y de forma asimétrica.
- **El techo de esta tarea lo pone el etiquetado, no la arquitectura.**
- Sin acuerdo inter-evaluador reportado no sabemos cuánto del error residual es del modelo y cuánto es ruido de la etiqueta.
- **Trabajo futuro, en orden de retorno esperado:**
 - 1) Recolectar fotos de celular en condiciones reales chilenas y medir la caída. 2) Pérdida ordinal explícita (CORAL) en vez de entropía cruzada plana. 3) Predicción de vida útil restante en días, que es la pregunta que de verdad importa en la cadena de frío.

 github.com/cmartinez1524/clasificacion-de-paltas