Clasificación del estado de madurez de paltas Hass

ResNet-50, ViT-S/16 e híbridos con presupuesto equiparado

Cristóbal Martínez, Benjamín Espinoza, Felipe Alvarez, Felipe Torres, Felipe Rojo

Entrega final, 23 de noviembre de 2026

14.710 fotografías, 478 frutas, índice ordinal de 5 niveles

El problema

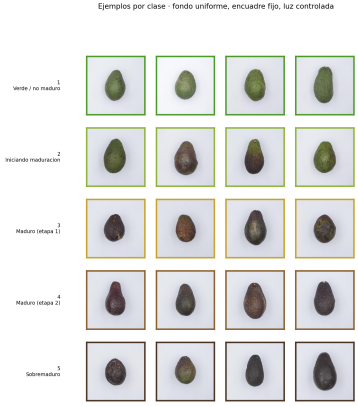
- **Chile es uno de los mayores exportadores de palta Hass del mundo.**
- La clasificación por madurez se hace hoy a ojo y al tacto, operario por operario, sin criterio homogéneo ni trazabilidad.
- **La tarea es *ordinal* y asimétrica:** $1 < 2 < 3 < 4 < 5$**.**
- La palta es climatérica (libera etileno). Clasificar una fruta madura como inmadura ($\hat{y} < y$) mete fruta madura al lote verde y echa a perder las demás.
- Clasificar una verde como madura ($\hat{y} > y$) solo adelanta su salida: es un error mucho menos costoso.

Índ.	Estado	Decisión
1	Verde	Dejar madurar
2	Iniciando	Lista en 2–3 días
3	Maduro I	Venta inmediata
4	Maduro II	Último día
5	Sobremaduro	Fuera de punto

Medimos distancia (QWK) y dirección del error: MAE Asimétrico con castigo $2\times$ al falso inmaduro.

Los datos en imágenes: 5 etapas de madurez

Hass Avocado Ripening Photographic Dataset (Mendeley, CC BY 4.0)

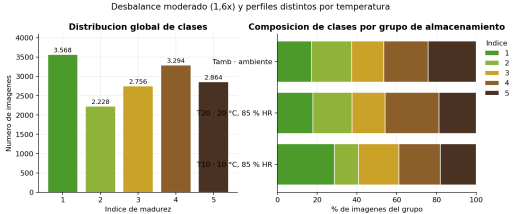


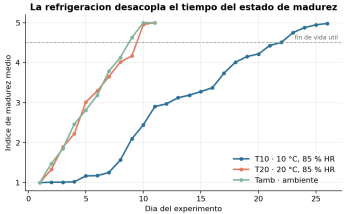
Índ.	Estado	Decisión
1	Verde	Dejar madurar
2	Iniciando	Lista en 2–3 días
3	Maduro I	Venta inmediata
4	Maduro II	Último día
5	Sobremaduro	Fuera de punto

- **14.710 fotos JPEG de 800×800 px de 478 paltas Hass.**
- Adquiridas 3 días tras la cosecha (abril 2022, Portugal) y fotografiadas **a diario por ambas caras** (a y b) durante hasta 26 días.
- **Captura estandarizada:** fondo blanco uniforme, luz difusa fija y una sola fruta centrada por foto.
- **Integridad verificada:** descartamos 12 filas de la planilla sin imagen; 0 discrepancias entre Excel y archivo.
- **Etiquetado visual experto:** sin penetrómetro ni doble evaluador (fronteras como 3↔4 son continuas).

Diseño experimental: 3 temperaturas y evolución temporal

Cómo se distribuyen las clases y cómo madura cada grupo





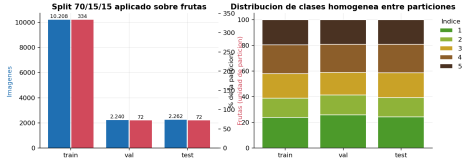
- **T10 (10 °C):** 192 frutas, 8.866 fotos (60 % del total; pasan muchos días verdes).
- **T20 (20 °C) y Tamb:** 143 frutas y ~2.920 fotos cada uno.

- A 20 °C o ambiente maduran en 10 días; a 10 °C tardan más de 3 semanas.
- Desbalance moderado ($1{,}6\times$) compensado con pesos de clase en la pérdida.

Dos paltas del mismo día a distinta temperatura tienen madurez opuesta, y dentro de cada grupo hay frutas fuera de ritmo.

El riesgo de que la IA haga trampa

- **A cada palta le sacaron una foto por día, hasta 26 días seguidos.**
- La foto del día 5 y la del día 6 de la misma palta son casi idénticas: misma piel, mismas manchas, misma forma.
- **Si repartimos las fotos al azar, la trampa es inevitable.**
- El día 5 queda en el material de estudio y el día 6 en la prueba. El modelo *reconoce esa palta* en vez de juzgar su madurez, como un alumno que vio las respuestas antes del examen.
- El resultado saldría altísimo y sería completamente falso.
- **Por eso repartimos las 478 paltas, no las 14.710 fotos.**
- Todas las fotos de una misma palta van juntas: o están en el estudio, o están en la prueba. Nunca en las dos.



Implementamos un chequeo automático que falla si alguna palta llegara a aparecer en los dos lados.

Limitaciones conocidas de los datos

Lo que declaramos antes de pensar en llevar esto a una planta

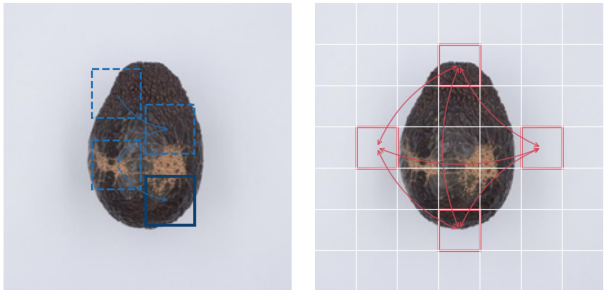
- **El choque con la vida real (domain gap): no resuelto, declarado.**
- Fondo blanco, luz perfecta y una sola fruta centrada. Una foto de celular en una feria o packing —con sombras, cajones y varias paltas— está fuera de la distribución de entrenamiento.
- **Un solo lote, una sola cosecha, una sola variedad.**
- 478 paltas portuguesas de 2022, todas Hass. No cubre Fuerte ni Edranol ni posibles variaciones de pigmentación en fruta chilena.
- **Solo apariencia externa y sin doble evaluador.**
- Las etiquetas las puso una persona mirando la cáscara; defectos internos de pulpa no se ven y no conocemos el techo humano.

Detalle completo en la data card (`entregables/final/data_card.md`).

Las dos redes, en una imagen

La diferencia es CÓMO miran la foto

ResNet-50 · una lupa que recorre la fruta **ViT-S/16 · un rompecabezas que conversa**



- Va de a pedacitos y reutiliza el mismo detector en toda la foto *(convolución)*.
- Buena para detalles: manchas, arrugas, tono.

- Parte la foto en 196 cuadraditos y los compara todos contra todos *(auto-atención)*.
- Buena para relacionar zonas distantes.

Ninguna se programó desde cero: las dos vienen de `timm`, la biblioteca estándar de modelos de visión.

Por qué entrenan tan distinto

Todo se explica por lo que cada red ya sabe antes de empezar

ResNet-50 trae dos reglas de fábrica

- Lo que importa está **cerca**
- **No importa** en qué parte de la foto esté

Una mancha café es una mancha café, arriba o abajo de la fruta.

Eso no lo aprende: ya lo trae.

ViT-S/16 no trae ninguna

- Todos los cuadraditos le parecen **iguales**
- Ni siquiera sabe cuáles son **vecinos**

Tiene que deducir de los ejemplos hasta la noción de «al lado».

- **El ViT necesita muchísimos más ejemplos.**
- La ResNet arranca sabiendo mirar imágenes; el ViT tiene que descubrir primero *cómo* se mira una imagen, y recién después aprender de paltas.
- **Por eso los dos parten desde ImageNet.**
- Antes de ver una sola palta ya vieron 1,3 millones de fotos de cosas cotidianas. Ahí el ViT compensa su desventaja y llega con el oficio aprendido.

Los dos híbridos

Dos formas distintas de juntar ambas ideas

1. Fusión tardía

- Las dos redes miran la misma foto por separado y al final se juntan sus dos opiniones para decidir.
- Como pedir una segunda opinión médica.
- Es el único modelo que escribimos nosotros (`src/paltas/models.py`).
- **Cuesta el doble: corre las dos redes enteras.**

2. ViT-Hybrid R26+S/32

- Una sola red: la parte convolucional procesa la foto primero y le entrega el resultado al transformer.
- En vez de dos opiniones, es una cadena de montaje.
- Es la arquitectura del paper original de ViT.
- **Tiene ventaja: más parámetros y más pre-entrenamiento.**

Ninguno de los dos es equiparable a los baselines, y hay que decirlo: van como referencia, no como competidores.

Cómo hacemos que la comparación sea justa

Igualar tres cosas, no solo el tamaño

Qué igualamos	ResNet-50	ViT-S/16	Diferencia
Tamaño del «cerebro» (conexiones)	23,5 millones	21,7 millones	7,9 %
Esfuerzo que hace por foto	8,2 mil millones	8,5 mil millones	3,6 %
Fotos que vio antes de empezar	1,3 millones	1,3 millones	ninguna

- **Si una red es más grande y gana, no aprendimos nada: ganó por grande.**
- Por eso igualamos el tamaño (parámetros), el trabajo que hace por foto (GFLOPs) y cuántas fotos vio antes.
- El ViT que usa todo el mundo viene entrenado con 14 millones de fotos; la ResNet, con 1,3 millones. Comparándolos así estaríamos midiendo quién estudió más, no qué arquitectura es mejor.
- Usamos una versión del ViT llamada **DeiT-S**: es exactamente la misma red, pero entrenada con las mismas 1,3 millones de fotos que la ResNet. Ahí sí la comparación es limpia.

Cómo las entrenamos

Idéntico para ambas

- Las mismas fotos, en el mismo orden
- Las mismas deformaciones de las fotos
- La misma cantidad de vueltas al dataset
- El mismo criterio para elegir el mejor modelo
- El mismo criterio para cortar el entrenamiento

Distinto en el ViT

- **Learning rate 3 veces más pequeño.**
- Es el tamaño del paso. Con pasos largos el ViT tropieza y deja de aprender.
- **Y un arranque más lento (*warmup*).**
- Las primeras vueltas van a media máquina, pero a la larga es lo mejor para el ViT.

Observación: en casi cualquier otra tarea conviene alterar mucho los colores de las fotos de entrenamiento, para que el modelo no dependa del color. Acá el color *es* la respuesta: si alteramos mucho el tono, una palta clase 2 se vuelve idéntica a una clase 4 pero con la etiqueta vieja. Le estaríamos enseñando mal. Por eso el color casi no se toca; girar y recortar la foto, en cambio, sí.

> Igualar el learning rate «por justicia» no sería más justo: sería solo peor para el ViT.

01 Resultados

La vara que hay que superar: el calendario

Una regla que no mira la foto: solo la temperatura y el día de almacenamiento

La regla

Para cada temperatura y cada día, mirar en las paltas de estudio cuál fue el estado más común, y responder eso. No ve la foto.

Lo que logra

Acierta la clase exacta en el **78,0 %** de las fotos de prueba, QWK 0,942. Más que cualquiera de las dos redes mirando solo la foto.

- **¿Por qué funciona tan bien?**
- En este experimento las paltas se cosecharon juntas y se guardaron en condiciones controladas: maduran casi al mismo ritmo. Saber cuántos días lleva guardada una palta ya dice casi todo.
- **Entonces, ¿para qué la foto?**
- Para las paltas que no siguen el ritmo del grupo, y para cuando no se sabe la historia de la fruta. Eso es lo que medimos a continuación.

Esta comparación la pidió el profesor en el avance. Toda la sección de resultados se mide contra esta regla.

Todos los modelos, lado a lado

2.262 fotos de 72 paltas que ningún modelo vio; incluye entrenamiento asimétrico

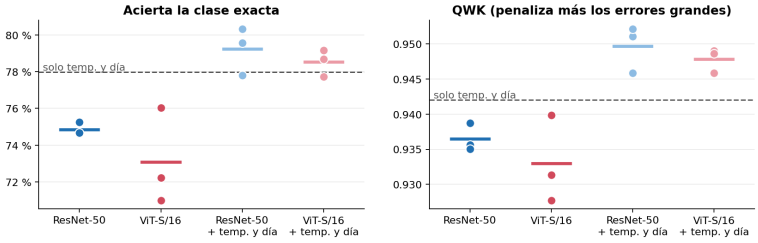
Modelo	Sem.	Clase exacta	QWK	MAE	MAE Asim.
Solo temperatura y día (sin foto)	1	78,0 %	0,942	0,23	0,343
ResNet-50	3	$74{,}8 \pm 0{,}3$ %	0,936	0,26	0,383
ViT-S/16	3	$73{,}1 \pm 2{,}6$ %	0,933	0,28	0,412
ResNet-50 + temp. y día	3	$79{,}2 \pm 1{,}3$ %	0,950	0,21	0,308
ViT-S/16 + temp. y día	3	$78{,}5 \pm 0{,}7$ %	0,948	0,22	0,328
ResNet-50 (asim.)	1	72,2 %	0,930	0,29	0,353
ViT-S/16 (asim.)	1	74,8 %	0,938	0,26	0,356

- **La foto sola queda bajo la regla del calendario en promedio global.**
- Pero en las paltas que maduran fuera de ritmo, la regla del calendario falla siempre.
- **El entrenamiento asimétrico logra el menor MAE Asimétrico sin metadatos.**
- **ResNet-50 (asim.)** baja el MAE Asimétrico a 0,353 (reduciendo los falsos inmaduros a 6,5 %) y **ViT-S/16 (asim.)** alcanza 74,8 % de exactitud y QWK 0,938.
- **El $\pm$ es lo que cambia el resultado al repetir el entrenamiento.**
- El ViT varía cerca de 9 veces más que la ResNet entre un entrenamiento y otro.

Los modelos desde cero y los híbridos (2 híbridos) van más adelante y en el anexo.

ResNet-50 frente a ViT-S/16

Tres entrenamientos de cada una: cada punto es uno, la raya es el promedio

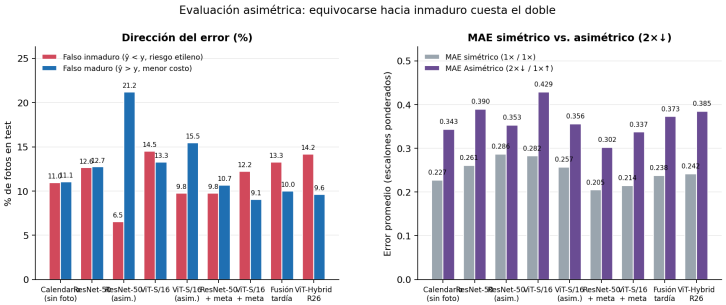


- **En promedio la ResNet acierta un poco más: 74,8 ± 0,3 % contra 73,1 ± 2,6 %.**
- Gana con claridad en 2 de 3 semillas en clase exacta y en 1 de 3 en QWK. En la otra semilla el ViT queda arriba, sin diferencia clara.
- **La diferencia más clara es la estabilidad.**
- La ResNet da casi lo mismo cada vez; el ViT sale entre 71,0 % y 76,0 % según la semilla.

En el avance dijimos «ResNet gana en clase exacta» con un solo entrenamiento. Con tres, la conclusión se matiza.

Dos direcciones del error, dos costos distintos

Semilla 42 de cada modelo; el costo elegido no mide etileno



Menos falsos inmaduros puede significar más falsos maduros. La tabla siguiente compara con la variación entre semillas.

Asimetría: menos falsos inmaduros, más falsos maduros

Costo elegido: subestimar pesa el doble; el etileno no se midió

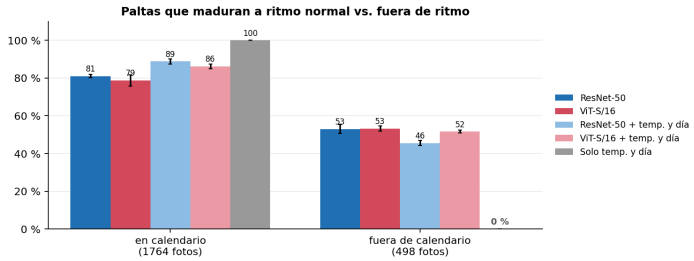
Modelo	Clase exacta	Subestim.	Sobreestim.	MAE asim.
Solo temp. y día	78,0 %	11,0 %	11,1 %	0,343
ResNet-50 (3 semillas)	74,6 %–75,2 %	11,1 %–13,2 %	11,6 %–14,3 %	0,373–0,390
ResNet asim. (1 semilla)	72,2 %	6,5 %	21,2 %	0,353
ViT-S/16 (3 semillas)	71,0 %–76,0 %	10,9 %–14,6 %	9,3 %–18,1 %	0,392–0,429
ViT asim. (1 semilla)	74,8 %	9,8 %	15,5 %	0,356

Tabla: rango de tres semillas en baselines; asimétricos: solo 42. El ViT asimétrico queda dentro del rango de accuracy y QWK del ViT normal.

Castigar el falso inmaduro lo reduce casi a la mitad en ResNet, a cambio de más falsos maduros y menos aciertos exactos. Una semilla: resultado preliminar.

¿Qué aporta realmente la foto?

Separando las paltas según si maduran al ritmo de su grupo

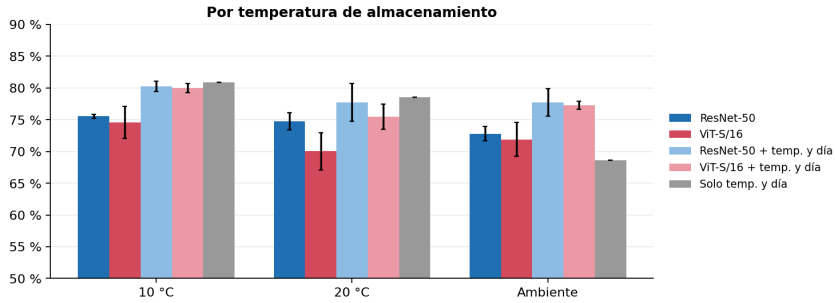


- **498 de 2.262 fotos son de paltas que van fuera de ritmo. Ahí la regla del calendario falla siempre; la foto sola acierta cerca de la mitad.**
- Al darle también temperatura y día, la ResNet baja de 52,9 % a 45,5 % en esos casos: aprende a confiar en el calendario y mira menos la foto justo donde más se necesitaba.

Lo que gana el modelo combinado lo gana en las paltas normales; en las raras, la foto sola sigue siendo mejor.

Por temperatura de almacenamiento

Corrección del avance: los modelos no rinden igual en las tres



- **A temperatura ambiente el calendario es el que más se equivoca.**
- La regla baja a 68,6 %; la ResNet con foto sola llega a 72,8 %. Sin refrigeración las paltas maduran más dispares y la foto aporta más.
- **En el avance dijimos que andaba igual de bien en las tres. No es así.**
- El ViT baja de 74,5 % a 10 °C a 70,0 % a 20 °C. La ResNet es más pareja.

Cómo se equivoca

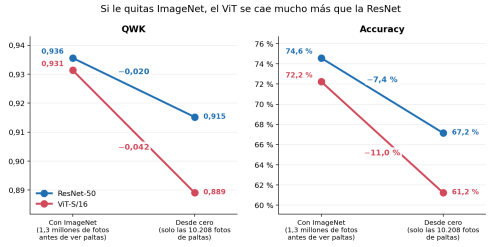
Fotos reales de la prueba, elegidas al azar entre los errores



557 de los 574 errores de la ResNet son de un escalón. Los estados 3, 4 y 5 se ven igual de oscuros: los separa la firmeza, que la foto no muestra. Las manchas claras de daño también confunden.

El experimento que lo demuestra

Reentrenamos las dos redes SIN ImageNet, solo con las fotos de paltas



- **El ViT pierde 2,1× más QWK y 1,5× más accuracy que la ResNet.**
- Es lo que predice la idea de las «reglas de fábrica»: la ResNet ya sabía mirar imágenes, el ViT tenía que aprenderlo, y 10.208 fotos de paltas no alcanzan para eso.
- Las cuatro caídas son estadísticamente sólidas ($p < 0{,}0001$), y cada red se compara contra *su propia* versión con ImageNet.
- Limitación: los modelos desde cero se entrenaron una sola vez. La caída es tan grande (7 y 11 puntos) que la variación entre semillas no alcanza a explicarla, pero el cociente exacto es aproximado.

Con ImageNet las dos quedan cerca. Sin ImageNet, no. La diferencia real entre ellas no es el techo, es cuántos datos necesitan para llegar.

Una hipótesis para explicarlo

Creemos que esta tarea juega en la cancha de la convolución

- **El estado de madurez se lee en detalles pequeños y locales.**
- El color de la cáscara, las manchas, el arrugamiento. Todo eso está repartido por la superficie de la fruta y se ve de cerca.
- **Justo lo que la ResNet hace bien con su lupa.**
- La gran ventaja del ViT es relacionar zonas lejanas de una imagen. Acá hay poco lejano que relacionar: todas las paltas tienen la misma forma, están centradas y sobre el mismo fondo.
- **Es una hipótesis, no un resultado.**
- Es coherente con la ablación y con los mapas de atención, pero no la probamos directamente. La prueba sería tapar o desordenar partes de la foto y ver cuál de las dos redes sufre más: queda como trabajo futuro.

Lo que sí podemos afirmar: con el mismo estudio previo quedan cerca, y sin él la ResNet resiste mucho mejor.

Los híbridos

¿Suma combinar ambos enfoques?

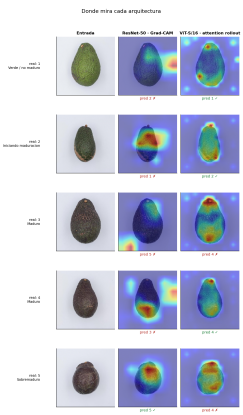
Modelo	QWK val.	Exacta val.	QWK prueba	Exacta prueba	Cuesta
ResNet-50	0,945	78,8 %	0,936	74,6 %	1,00×
Híbrido: fusión tardía	0,939	77,4 %	0,941	76,7 %	2,04×
ViT-Hybrid R26+S/32	0,943	78,0 %	0,941	76,2 %	0,84×

- **En la prueba parecían mejores. En validación, no.**
- Con la semilla 42 ambos superan a la ResNet en la prueba. Pero la decisión se toma en validación, y ahí ninguno le gana a la ResNet en QWK. Elegirlos mirando la prueba habría sido el mismo error que nos señalaron en el avance.
- **Además se entrenaron una sola vez.**
- La ResNet sola ya varía $\pm 0{,}3$ puntos entre semillas, y el ViT $\pm 2{,}6$: una ventaja de un punto con una sola semilla no alcanza para afirmar nada.
- **Y la fusión tardía cuesta el doble por foto.**
- El ViT-Hybrid R26 es más barato, pero estudió con 14 millones de fotos en vez de 1,3: no es una comparación limpia.

Conclusión: con esta evidencia, combinar las dos redes no demostró valer la pena. Agregar temperatura y día o pérdida asimétrica aportó más.

¿En qué se fijó el modelo para decidir?

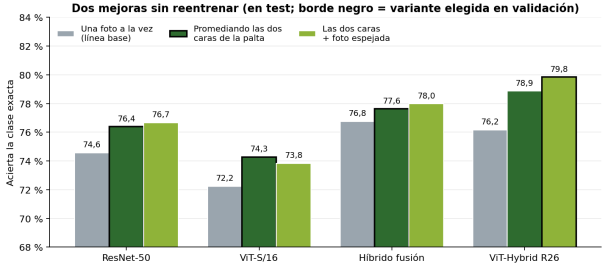
Pintamos sobre la foto las zonas que más pesaron en la respuesta



- Rojo = la zona que más influyó en la decisión; azul = la que casi no se usó.
- Cada red se abre con una técnica distinta, porque por dentro funcionan distinto. Las dos responden la misma pregunta.
- **La ResNet se concentra en puntos chicos: una mancha, una arruga, una zona oscura.**
- **El ViT reparte la mirada por áreas más grandes de la cáscara.**
- **Un hallazgo incómodo y honesto:**
- En varios de los casos en que las dos redes discrepan, la ResNet está mirando el *fondo*, fuera de la fruta. Y son justamente esos los casos en que se equivoca. Sin esta figura no lo habríamos notado.

Dos mejoras que salieron gratis

Sin reentrenar: se eligen en validación y recién después se miden en la prueba



- **1. Mirar las dos caras de la palta antes de decidir.**
- El dataset fotografía cada fruta por ambos lados el mismo día. Juntar las dos opiniones gana en validación en los cuatro modelos, y en la prueba sube a la ResNet de 74,6 % a 76,4 %. En una planta igual se fotografían las dos caras: es gratis.
- **2. Mostrarle también la foto espejada y promediar.**
- En validación solo le sirvió a ViT-Hybrid R26+S/32. A los demás no los mejora, así que no se les aplica.

Corrección respecto del avance: antes estas variantes se comparaban directo en la prueba. Ahora la prueba se mira una sola vez.

¿Cuál llevaríamos a una planta empacadora?

Depende de qué información se tenga y del costo de infiltrar fruta madura

Modelo	Clase exacta	Cuesta	Veredicto
ResNet-50 + temp. y día	79,2 ± 1,3 %	1,00×	La que recomendamos si se conoce la historia del lote.
Solo temperatura y día	78,0 %	casi 0	Empata en promedio. Pero falla siempre con las paltas fuera de ritmo.
ResNet-50	74,8 ± 0,3 %	1,00×	La opción estándar si no se sabe cuántos días lleva guardada la fruta.
ViT-S/16	73,1 ± 2,6 %	1,04×	Cerca en promedio, pero menos estable entre entrenamientos.
ResNet-50 (asim.)	72,2 %	1,00×	Preliminar (1 semilla): subest. 6,5 %, sobreest. 21,2 %; menos aciertos exactos.
ViT-S/16 (asim.)	74,8 %	1,04×	Preliminar (1 semilla): dentro del rango del ViT normal; sobreest. 15,5 %.

- **Si la planta registra temperatura y fecha de ingreso, hay que usarlas.**
- Mejoran a las dos redes en las 3 semillas; en QWK la mejora es significativa en todas. No cuesta nada: son dos números más.
- **La pérdida asimétrica requiere más semillas antes de recomendar su uso.**
- Reduce falsos inmaduros a cambio de más falsos maduros; el riesgo de etileno no fue medido.
- **Entre ResNet y ViT, preferimos la ResNet.**
- No porque sea claramente más precisa, sino porque da lo mismo cada vez que se entrena. En producción eso importa.

Demo

Subir una foto y ver qué responde el modelo

- **Se elige el modelo, se sube la foto y aparece la respuesta.**
- Muestra qué tan seguro está de cada uno de los 5 estados, y qué hacer con esa palta: dejarla madurar, venderla hoy o descartarla.
- **Muestra también dónde miró para decidir.**
- No es una caja negra: se ve pintada sobre la foto la zona que usó.
- **Avisa cuando no está seguro.**
- Si duda entre dos estados vecinos lo dice, en vez de responder con falsa confianza. Ahí conviene que mire una persona.
- **Los ejemplos que trae cargados son paltas que ningún modelo vio nunca.**
- Y advierte en pantalla que fue entrenado con fotos de laboratorio.

`python app/gradio_app.py` → `http://localhost:7860`

Conclusiones y trabajo futuro

Qué aprendimos y qué sigue

- **En este dataset, el calendario explica la mayor parte de la madurez.**
- Una regla con solo temperatura y día acierta el 78 %; la foto aporta donde el calendario falla siempre: en las 498 fotos de paltas fuera de ritmo.
- **ResNet y ViT quedan cerca; la ResNet es más estable y depende menos de ImageNet.**
- Con tres entrenamientos, la ventaja de la ResNet en clase exacta aparece en dos de tres. Sin ImageNet, el ViT pierde el doble.
- **Penalización ordinal asimétrica: resultado preliminar, una semilla.**
- Menor MAE Asimétrico contra la semilla 42 del baseline ($p = 0{,}006$ ResNet; $p = 0{,}030$ ViT), con más sobreestimación. El efecto entre semillas y el riesgo de etileno no fueron medidos.
- **Qué haríamos ahora:**
- 1) Fotos de celular en un packing chileno, sin historia del lote (o reemplazo de fondos). 2) Combinar `AsymmetricOrdinalLoss` con el modelo de metadatos y 3 semillas. 3) Tapar partes de la foto para probar la hipótesis local vs. global.

`github.com/cmartinez1524/clasificacion-de-paltas`

A Anexo

Anexo: todas las métricas

Test, semilla 42: 2.262 imágenes de 72 frutas nunca vistas

Modelo	Params	GFLOPs	QWK	Accuracy	Macro-F1	MAE	MAE Asim.	Subest.	Acc. ± 1	min
ResNet-50	23,5 M	8,2	0,9356	74,6 %	0,735	0,261	0,390	12,6 %	99,2 %	10
ViT-S/16	21,7 M	8,5	0,9313	72,2 %	0,711	0,282	0,429	14,5 %	99,5 %	5
ResNet-50 (asim.)	23,5 M	8,2	0,9296	72,2 %	0,717	0,286	0,353	6,5 %	99,1 %	23
ViT-S/16 (asim.)	21,7 M	8,5	0,9379	74,8 %	0,740	0,257	0,356	9,8 %	99,5 %	17
ResNet-50 + temp. y día	23,5 M	8,2	0,9511	79,6 %	0,789	0,205	0,302	9,8 %	100,0 %	10
ViT-S/16 + temp. y día	21,7 M	8,5	0,9490	78,7 %	0,778	0,214	0,337	12,2 %	99,9 %	6
ResNet-50 (scratch)	23,5 M	8,2	0,9152	67,2 %	0,655	0,352	0,452	9,6 %	97,7 %	18
ViT-S/16 (scratch)	21,7 M	8,5	0,8891	61,2 %	0,579	0,409	0,658	23,5 %	98,1 %	6
Híbrido: fusión tardía	46,4 M	16,7	0,9410	76,7 %	0,760	0,238	0,373	13,3 %	99,5 %	4
ViT-Hybrid R26+S/32	36,0 M	6,9	0,9411	76,2 %	0,752	0,242	0,385	14,2 %	99,6 %	15

- **QWK**: kappa de Cohen con pesos cuadráticos. Penaliza el error según el cuadrado de la distancia entre clases y corrige por acuerdo azaroso. Es la métrica con la que elegimos el mejor modelo.
- **MAE Asim.**: error ponderado que castiga $2\times$ clasificar una palta madura como inmadura ($\hat{y} < y$, columna **Subest.**) frente a $1\times$ por sobreestimar ($\hat{y} > y$).
- **Acc. ± 1**: fracción de predicciones en la clase correcta o una adyacente.
- **Macro-F1**: F1 promediado por clase; controla que las clases minoritarias no queden abandonadas.

Anexo: pruebas estadísticas

Semilla 42: diferencias contra ResNet-50, con intervalo de confianza del 95 %

- **ViT-S/16:** Δ**QWK** $=$-0,0043**, IC 95 %** [-0,0094, +0,0001]**,** $p = 0{,}060 \rightarrow$ **NO significativa** | Δ**MAE Asim.** $= +0{,}0393$ ($p = 0{,}004$**, significativa**)
- **ResNet-50 (asim.):** Δ**QWK** $=$-0,0060**, IC 95 %** [-0,0118,-0,0011]**,** $p = 0{,}032 \rightarrow$ **significativa** | Δ**MAE Asim.** $=$-0,0367 ($p = 0{,}004$**, significativa**)
- **ViT-S/16 (asim.):** Δ**QWK** $= +0{,}0022$**, IC 95 %** [-0,0038, +0,0079]**,** $p = 0{,}500 \rightarrow$ **NO significativa** | Δ**MAE Asim.** $=$-0,0336 ($p = 0{,}032$**, significativa**)
- **ResNet-50 + temp. y día:** Δ**QWK** $= +0{,}0155$**, IC 95 %** [+0,0089, +0,0231]**,** $p = 0{,}000 \rightarrow$ **significativa** | Δ**MAE Asim.** $=$-0,0875 ($p = 0{,}000$**, significativa**)
- **ViT-S/16 + temp. y día:** Δ**QWK** $= +0{,}0134$**, IC 95 %** [+0,0071, +0,0200]**,** $p = 0{,}000 \rightarrow$ **significativa** | Δ**MAE Asim.** $=$-0,0526 ($p = 0{,}000$**, significativa**)
- **ResNet-50 (scratch):** Δ**QWK** $=$-0,0204**, IC 95 %** [-0,0280,-0,0124]**,** $p = 0{,}000 \rightarrow$ **significativa** | Δ**MAE Asim.** $= +0{,}0623$ ($p = 0{,}012$**, significativa**)
- **ViT-S/16 (scratch):** Δ**QWK** $=$-0,0466**, IC 95 %** [-0,0689,-0,0317]**,** $p = 0{,}000 \rightarrow$ **significativa** | Δ**MAE Asim.** $= +0{,}2683$ ($p = 0{,}000$**, significativa**)
- **Híbrido: fusión tardía:** Δ**QWK** $= +0{,}0054$**, IC 95 %** [+0,0022, +0,0085]**,** $p = 0{,}000 \rightarrow$ **significativa** | Δ**MAE Asim.** $=$-0,0172 ($p = 0{,}072$**, NO significativa**)
- **ViT-Hybrid R26+S/32:** Δ**QWK** $= +0{,}0054$**, IC 95 %** [+0,0009, +0,0104]**,** $p = 0{,}028 \rightarrow$ **significativa** | Δ**MAE Asim.** $=$-0,0049 ($p = 0{,}756$**, NO significativa**)
- Los intervalos y los p-valores salen de un *bootstrap pareado agrupado por fruta*: las 2.262 imágenes vienen de solo 72 paltas, así que remuestrear imágenes daría intervalos artificialmente angostos. Se remuestrean frutas, 2.000 réplicas.

Anexo: tres semillas

Media ± desviación estándar en la prueba (semillas 42, 1 y 2)

Modelo	Accuracy	QWK	Macro-F1	MAE	QWK val.
ResNet-50	74,8 ± 0,3 %	0,9365 ± 0,0020	0,740 ± 0,004	0,258 ± 0,005	0,9418
ViT-S/16	73,1 ± 2,6 %	0,9330 ± 0,0062	0,719 ± 0,030	0,276 ± 0,031	0,9312
ResNet-50 + temp. y día	79,2 ± 1,3 %	0,9497 ± 0,0034	0,785 ± 0,014	0,208 ± 0,013	0,9523
ViT-S/16 + temp. y día	78,5 ± 0,7 %	0,9478 ± 0,0017	0,778 ± 0,007	0,217 ± 0,008	0,9501
Solo temperatura y día	78,0 %	0,9420	0,770	0,227	0,9437

Anexo: comparaciones pareadas entre modelos

Bootstrap pareado agrupado por fruta, 2.000 réplicas, semilla por semilla

Comparación	Semilla	ΔQWK	p	ΔAcc.	p
ResNet − ViT	1	−0,0011	0,700	−0,008	0,433
ResNet − ViT	2	+0,0073	0,029	+0,037	0,003
ResNet − ViT	42	+0,0043	0,085	+0,024	0,021
ResNet+meta − ResNet	1	+0,0071	0,022	+0,026	0,018
ResNet+meta − ResNet	2	+0,0171	0,000	+0,057	0,000
ResNet+meta − ResNet	42	+0,0155	0,000	+0,050	0,000
ViT+meta − ViT	1	+0,0060	0,024	+0,017	0,099
ViT+meta − ViT	2	+0,0209	0,000	+0,082	0,000
ViT+meta − ViT	42	+0,0177	0,000	+0,065	0,000
ResNet+meta − ViT+meta	1	+0,0000	0,967	+0,001	0,925
ResNet+meta − ViT+meta	2	+0,0035	0,174	+0,011	0,240
ResNet+meta − ViT+meta	42	+0,0021	0,439	+0,009	0,398

Anexo: cada modelo contra la regla del calendario

Bootstrap pareado agrupado por fruta, 2.000 réplicas, semilla por semilla

Comparación	Semilla	ΔQWK	p	ΔAcc.	p
ResNet — Calendario	42	−0,0064	0,363	−0,034	0,057
ResNet — Calendario	1	−0,0033	0,612	−0,027	0,145
ResNet — Calendario	2	−0,0070	0,328	−0,033	0,079
ViT — Calendario	42	−0,0107	0,149	−0,057	0,007
ViT — Calendario	1	−0,0022	0,712	−0,019	0,289
ViT — Calendario	2	−0,0143	0,106	−0,070	0,004
ResNet+meta — Calendario	42	+0,0091	0,102	+0,016	0,325
ResNet+meta — Calendario	1	+0,0038	0,517	−0,002	0,936
ResNet+meta — Calendario	2	+0,0101	0,090	+0,023	0,159
ViT+meta — Calendario	42	+0,0070	0,235	+0,007	0,689
ViT+meta — Calendario	1	+0,0038	0,608	−0,003	0,904
ViT+meta — Calendario	2	+0,0066	0,310	+0,012	0,477

Anexo: accuracy por temperatura de almacenamiento

Media $\pm$ desviación entre semillas

Modelo	T10 (10 °C)	T20 (20 °C)	Tamb
ResNet	75,6 $\pm$ 0,3 %	74,7 $\pm$ 1,4 %	72,8 $\pm$ 1,1 %
ViT	74,5 $\pm$ 2,5 %	70,0 $\pm$ 2,9 %	71,9 $\pm$ 2,7 %
ResNet+meta	80,2 $\pm$ 0,8 %	77,8 $\pm$ 3,0 %	77,7 $\pm$ 2,1 %
ViT+meta	80,0 $\pm$ 0,7 %	75,5 $\pm$ 1,9 %	77,3 $\pm$ 0,6 %
Calendario	80,9 %	78,5 %	68,6 %