

Clasificación del estado de madurez de paltas Hass

ResNet-50, ViT-S/16 e híbridos con presupuesto equiparado

Cristóbal Martínez, Benjamín Espinoza, Felipe Alvarez, Felipe Torres, Felipe Rojo

Entrega final, 23 de noviembre de 2026

14.710 fotografías, 478 frutas, índice ordinal de 5 niveles

El problema

- Chile es uno de los mayores exportadores de palta Hass del mundo.
- La clasificación por madurez se hace hoy a ojo y al tacto, operario por operario, sin criterio homogéneo ni trazabilidad.
- Fruta verde en góndola: el consumidor la descarta. Fruta pasada en tránsito: pérdida total. Los dos errores cuestan.
- La tarea es **ordinal**, no categórica: $1 < 2 < 3 < 4 < 5$.
- Confundir un 1 con un 2 es un error de un día. Confundir un 1 con un 5 es mandar fruta podrida a la venta.

Índ.	Estado	Decisión
1	Verde	Dejar madurar
2	Iniciando	Lista en 2–3 días
3	Maduro I	Venta inmediata
4	Maduro II	Último día
5	Sobremaduro	Fuera de punto

La métrica tiene que castigar más los errores lejanos. La accuracy plana no lo hace: por eso usamos QWK.

Datos y limitaciones

Hass Avocado Ripening Photographic Dataset, Mendeley, CC BY 4.0

Imágenes

14.710

Frutas

478

Train/val/test

334/72/72

Licencia

CC BY 4.0



- **Que la IA hiciera trampa: resuelto.**
- Hay 6.871 pares de fotos casi idénticas de la misma palta en días seguidos. Repartimos las 478 paltas, no las 14.710 fotos, con un chequeo automático que falla si alguna aparece en los dos lados.
- **El choque con la vida real: no resuelto, declarado.**
- Son fotos de laboratorio: fondo blanco, una sola fruta centrada, luz pareja, siempre a la misma distancia. Una foto de celular en una feria no se parece en nada. Es la limitación que decide si esto sirve en una planta empacadora o solo en un informe.
- **Un solo lote, una sola cosecha, una sola variedad.**
- 478 paltas portuguesas de 2022, todas Hass. Y las etiquetas las puso una persona mirando, sin una segunda opinión con qué contrastar: no sabemos cuánto acertaría un experto humano en esta misma tarea.

Detalle completo en la data card ([entregables/final/data_card.md](#)).

Las dos redes, en una imagen

La diferencia es CÓMO miran la foto

ResNet-50 · una lupa que recorre la fruta ViT-S/16 · un rompecabezas que conversa



- Va de a pedacitos y reutiliza el mismo detector en toda la foto (*convolución*).
- Buena para detalles: manchas, arrugas, tono.

- Parte la foto en 196 cuadraditos y los compara todos contra todos (*auto-atención*).
- Buena para relacionar zonas distantes.

Ninguna se programó desde cero: las dos vienen de timm, la biblioteca estándar de modelos de visión.

Por qué entrenan tan distinto

Todo se explica por lo que cada red ya sabe antes de empezar

ResNet-50 trae dos reglas de fábrica

- Lo que importa está **cerca**
- **No importa** en qué parte de la foto esté

Una mancha café es una mancha café, arriba o abajo de la fruta.

Eso no lo aprende: ya lo trae.

ViT-S/16 no trae ninguna

- Todos los cuadraditos le parecen **iguales**
- Ni siquiera sabe cuáles son **vecinos**

Tiene que deducir de los ejemplos hasta la noción de «al lado».

- **El ViT necesita muchísimos más ejemplos.**
- La ResNet arranca sabiendo mirar imágenes; el ViT tiene que descubrir primero *cómo* se mira una imagen, y recién después aprender de paltas.
- **Por eso los dos parten desde ImageNet.**
- Antes de ver una sola palta ya vieron 1,3 millones de fotos de cosas cotidianas. Ahí el ViT compensa su desventaja y llega con el oficio aprendido.

Los dos híbridos

Dos formas distintas de juntar ambas ideas

1. Fusión tardía

- Las dos redes miran la misma foto por separado y al final se juntan sus dos opiniones para decidir.
- Como pedir una segunda opinión médica.
- Es el único modelo que escribimos nosotros (`src/paltas/models.py`).
- **Cuesta el doble: corre las dos redes enteras.**

2. ViT-Hybrid R26+S/32

- Una sola red: la parte convolucional procesa la foto primero y le entrega el resultado al transformer.
- En vez de dos opiniones, es una cadena de montaje.
- Es la arquitectura del paper original de ViT.
- **Tiene ventaja: más parámetros y más pre-entrenamiento.**

| Ninguno de los dos es equiparable a los baselines, y hay que decirlo: van como referencia, no como competidores.

Cómo hacemos que la comparación sea justa

Igualar tres cosas, no solo el tamaño

Qué igualamos	ResNet-50	ViT-S/16	Diferencia
Tamaño del «cerebro» (conexiones)	23,5 millones	21,7 millones	7,9 %
Esfuerzo que hace por foto	8,2 mil millones	8,5 mil millones	3,6 %
Fotos que vio antes de empezar	1,3 millones	1,3 millones	ninguna

- Si una red es más grande y gana, no aprendimos nada: ganó por grande.
- Por eso igualamos el tamaño (parámetros), el trabajo que hace por foto (GFLOPs) y cuántas fotos vio antes.
- El ViT que usa todo el mundo viene entrenado con 14 millones de fotos; la ResNet, con 1,3 millones. Comparándolos así estaríamos midiendo quién estudió más, no qué arquitectura es mejor.
- Usamos una versión del ViT llamada **DeiT-S**: es exactamente la misma red, pero entrenada con las mismas 1,3 millones de fotos que la ResNet. Ahí sí la comparación es limpia.

Cómo las entrenamos

Idéntico para ambas

- Las mismas fotos, en el mismo orden
- Las mismas deformaciones de las fotos
- La misma cantidad de vueltas al dataset
- El mismo criterio para elegir el mejor modelo
- El mismo criterio para cortar el entrenamiento

Distinto en el ViT

- **Learning rate 3 veces más pequeño.**
- Es el tamaño del paso. Con pasos largos el ViT tropieza y deja de aprender.
- **Y un arranque más lento (*warmup*).**
- Las primeras vueltas van a media máquina, pero a la larga es lo mejor para el ViT.

Observación: en casi cualquier otra tarea conviene alterar mucho los colores de las fotos de entrenamiento, para que el modelo no dependa del color. Acá el color es la respuesta: si alteramos mucho el tono, una palta clase 2 se vuelve idéntica a una clase 4 pero con la etiqueta vieja. Le estaríamos enseñando mal. Por eso el color casi no se toca; girar y recortar la foto, en cambio, sí.

■ Igualar el learning rate «por justicia» no sería más justo: sería solo peor para el ViT.

01 Resultados

Todos los modelos, lado a lado

Medido sobre 2.262 fotos de 72 paltas que ningún modelo había visto


Modelo	Acierta o se pasa por un escalón	Error promedio	Clase exacta
ResNet-50	99,2 %	0,26 escalones	74,6 %
ViT-S/16	99,5 %	0,28 escalones	72,2 %
ResNet-50 (scratch)	97,7 %	0,35 escalones	67,2 %
ViT-S/16 (scratch)	98,1 %	0,41 escalones	61,2 %
Híbrido: fusión tardía	99,5 %	0,24 escalones	76,7 %
ViT-Híbrido R26+S/32	99,6 %	0,24 escalones	76,2 %

- **Todos los modelos con pre-entrenamiento están sobre el 99 %.**
- La diferencia entre ellos es de décimas. Los dos que aparecen abajo son los entrenados desde cero, y se nota.
- **El renglón que importa es el del medio.**
- Menos de medio escalón de error promedio significa, en la práctica, medio día de maduración.

La tabla completa, con las seis métricas técnicas, está en el anexo.

ResNet-50 frente a ViT-S/16

El resultado central del avance




- Las dos rinden prácticamente igual.
- La ResNet acierta la clase exacta un poco más seguido. Pero cuando el ViT se equivoca, se equivoca por menos. Se compensa.
- Hicimos la prueba estadística formal y la diferencia entre ambas no es concluyente: para efectos prácticos, empatan.
- Pero no se equivocan en las mismas fotos.
- Fallan las dos a la vez en solo 18,0 % de los casos. Si alguien pudiera elegir siempre cuál de las dos tiene razón, acertaría 82,0 % en vez de 74,6 %.
- Eso es lo que van a intentar aprovechar los modelos híbridos.

Los números completos y las pruebas estadísticas están en el anexo.

El experimento que lo demuestra

Reentrenamos las dos redes SIN ImageNet, solo con las fotos de paltas

Si le quitas ImageNet, el ViT se cae mucho más que la ResNet



- El ViT pierde $2,1\times$ más QWK y $1,5\times$ más accuracy que la ResNet.
- Es lo que predice la idea de las «reglas de fábrica»: la ResNet ya sabía mirar imágenes, el ViT tenía que aprenderlo, y 10.208 fotos de paltas no alcanzan para eso.
- Las cuatro caídas son estadísticamente sólidas ($p < 0,0001$), y cada red se compara contra *su propia* versión con ImageNet.

Con ImageNet las dos empatan. Sin ImageNet, no. La diferencia real entre ellas no es el techo, es cuántos datos necesitan para llegar.

Y hay una segunda razón

Esta tarea juega en la cancha de la convolución

- **El estado de madurez se lee en detalles pequeños y locales.**
- El color de la cáscara, las manchas, el arrugamiento. Todo eso está repartido por la superficie de la fruta y se ve de cerca.
- **Justo lo que la ResNet hace bien con su lupa.**
- La gran ventaja del ViT es relacionar zonas lejanas de una imagen. Acá no hay nada lejano que relacionar: todas las paltas tienen la misma forma, están centradas y sobre el mismo fondo.
- **Por eso el empate no es casualidad.**
- En un problema donde importara la composición global de la escena, probablemente el ViT sacaría ventaja. En este, su superpoder no suma.

■ Conclusión honesta: no es que el ViT sea peor, es que este problema no le pide lo que él hace mejor.

Los híbridos

¿Suma combinar ambos enfoques?

Híbrido: fusión tardía

QWK 0,941


ViT-Hybrid R26+S/32

QWK 0,941

- Híbrido: fusión tardía: 46,4 M params, 16,7 GFLOPs, acc 76,7 %
- ViT-Hybrid R26+S/32: 36,0 M params, 6,9 GFLOPs, acc 76,2 %


- En su tabla de desacuerdo, fusión y ResNet fallan *a la vez* en 20,6 % de las imágenes: más que el 18,0 % del par ResNet/ViT. La fusión no elimina los casos difíciles, los absorbe.
- La fusión tardía cuesta el doble de cómputo por imagen.
- Dos backbones completos en el forward. La pregunta no es si mejora, sino si mejora lo suficiente para justificar $2\times$ de latencia.
- Alcanza su mejor checkpoint en la **época 2** (3,5 min) con los backbones congelados: las representaciones ya contenían la información, lo que faltaba era combinarlas.

Costo computacional frente a desempeño



¿En qué se fijó el modelo para decidir?


Pintamos sobre la foto las zonas que más pesaron en la respuesta



- Rojo = la zona que más influyó en la decisión; azul = la que casi no se usó.
- Cada red se abre con una técnica distinta, porque por dentro funcionan distinto. Las dos responden la misma pregunta.
- La ResNet se concentra en puntos chicos: una mancha, una arruga, una zona oscura.
- El ViT reparte la mirada por áreas más grandes de la cáscara.
- Un hallazgo incómodo y honesto:
- En varios de los casos en que las dos redes discrepan, la ResNet está mirando el *fondo*, fuera de la fruta. Y son justamente esos los casos en que se equivoca. Sin esta figura no lo habríamos notado.

Dos mejoras que salieron gratis

Sin reentrenar nada, solo cambiando cómo se usa el modelo ya entrenado



- 1. Mirar las dos caras de la palta antes de decidir.
- El dataset fotografía cada fruta por ambos lados el mismo día. Hasta ahora clasificábamos cada foto por separado; juntar las dos opiniones sube a la ResNet de 74,6 % a 76,4 %, y mejora a los cuatro modelos. En una planta igual se fotografían las dos caras: es gratis.
- 2. Mostrarle también la foto espejada y promediar.
- Ayuda a las convolucionales, pero al ViT lo empeora un poco. Lo reportamos así: no todas las recetas estándar sirven en todos los modelos.

Antes de comprar más cómputo conviene revisar si se está usando bien el modelo que ya se tiene.

¿Cuál llevaríamos a una planta empacadora?

No gana el más preciso: gana el que rinde mejor por lo que cuesta

Modelo	Acierta o se pasa por uno	Cuesta	Veredicto
ResNet-50	99,2 %	1,00×	La que recomendamos. Es la referencia.
ViT-S/16	99,5 %	1,04×	Empata, cuesta lo mismo y se entrena en la mitad del tiempo.
Híbrido: fusión tardía	99,5 %	2,04×	Mejora poquito y cuesta el doble. No lo vale.
ViT-Hybrid R26+S/32	99,6 %	0,84×	Mejor y más barato, pero estudió con más fotos: no es comparación limpia.

- **En una planta hay que clasificar miles de paltas por hora.**
- Probablemente en un computador común, sin tarjeta gráfica potente. Ahí el costo de cada foto importa tanto como el acierto.
- **Si dos modelos empatan, gana el más barato.**
- Duplicar el costo para ganar unas décimas no se justifica.
- **Y ya estamos en el techo de lo exigible.**
- Con más del 99 % de aciertos dentro de un escalón, lo que queda de error probablemente también lo cometería una persona.

Demo

Subir una foto y ver qué responde el modelo

- **Se elige el modelo, se sube la foto y aparece la respuesta.**
- Muestra qué tan seguro está de cada uno de los 5 estados, y qué hacer con esa palta: dejarla madurar, venderla hoy o descartarla.
- **Muestra también dónde miró para decidir.**
- No es una caja negra: se ve pintada sobre la foto la zona que usó.
- **Avisa cuando no está seguro.**
- Si duda entre dos estados vecinos lo dice, en vez de responder con falsa confianza. Ahí conviene que mire una persona.
- **Los ejemplos que trae cargados son paltas que ningún modelo vio nunca.**
- Y advierte en pantalla que fue entrenado con fotos de laboratorio.

`python app/gradio_app.py → http://localhost:7860`

Conclusiones y trabajo futuro

Qué aprendimos y qué sigue

- **Con el mismo tamaño y el mismo estudio previo, las dos redes resuelven esto igual de bien.**
- La pregunta interesante no era cuál gana, sino en qué se diferencian. Y la diferencia no está en el techo que alcanzan: está en cuántos datos necesitan para llegar.
- **El límite de esta tarea lo pone quien etiquetó las fotos, no la red.**
- Como nadie revisó esas etiquetas dos veces, no sabemos cuánto del error que queda es del modelo y cuánto es desacuerdo entre humanos.
- **Qué haríamos ahora, en orden de importancia:**
 - 1) Salir a sacar fotos con celular en un packing chileno y medir cuánto cae. 2) Enseñarle explícitamente que las clases están ordenadas, cosa que hoy solo se le pide al evaluar. 3) Predecir directamente cuántos días de vida le quedan a la palta, que es lo que de verdad necesita la cadena de frío.

 github.com/cmartinez1524/clasificacion-de-paltas

A Anexo

Anexo: todas las métricas

Test: 2.262 imágenes de 72 frutas nunca vistas

Modelo	Params	GFLOPs	QWK	Accuracy	Macro-F1	MAE	Acc. ± 1	min
ResNet-50	23,5 M	8,2	0,9356	74,6 %	0,735	0,262	99,2 %	10
ViT-S/16	21,7 M	8,5	0,9313	72,2 %	0,711	0,282	99,5 %	5
ResNet-50 (scratch)	23,5 M	8,2	0,9152	67,2 %	0,655	0,352	97,7 %	18
ViT-S/16 (scratch)	21,7 M	8,5	0,8891	61,2 %	0,579	0,409	98,1 %	6
Híbrido: fusión tardía	46,4 M	16,7	0,9410	76,7 %	0,760	0,238	99,5 %	4
ViT-Hybrid R26+S/32	36,0 M	6,9	0,9411	76,2 %	0,752	0,242	99,6 %	15

- **QWK**: kappa de Cohen con pesos cuadráticos. Penaliza el error según el cuadrado de la distancia entre clases y corrige por acuerdo azaroso. Es la métrica con la que elegimos el mejor modelo.
- **MAE**: error medio en escalones del índice de madurez.
- **Acc. ± 1** : fracción de predicciones en la clase correcta o una adyacente.
- **Macro-F1**: F1 promediado por clase; controla que las clases minoritarias no queden abandonadas.

Anexo: pruebas estadísticas

Diferencias contra ResNet-50, con intervalo de confianza del 95 %

- ViT-S/16: $\Delta QWK = -0,0042$, IC 95 % $[-0,0095, +0,0006]$, $p = 0,095 \rightarrow$ **NO significativa**
- ResNet-50 (scratch): $\Delta QWK = -0,0203$, IC 95 % $[-0,0283, -0,0123]$, $p = 0,000 \rightarrow$ **significativa**
- ViT-S/16 (scratch): $\Delta QWK = -0,0465$, IC 95 % $[-0,0692, -0,0316]$, $p = 0,000 \rightarrow$ **significativa**
- Híbrido: fusión tardía: $\Delta QWK = +0,0055$, IC 95 % $[+0,0021, +0,0087]$, $p = 0,001 \rightarrow$ **significativa**
- ViT-Hybrid R26+S/32: $\Delta QWK = +0,0055$, IC 95 % $[+0,0005, +0,0104]$, $p = 0,031 \rightarrow$ **significativa**
- Los intervalos y los p -valores salen de un *bootstrap pareado agrupado por fruta*: las 2.262 imágenes vienen de solo 72 paltas, así que remuestrear imágenes daría intervalos artificialmente angostos. Se remuestran frutas, 2.000 réplicas.

Anexo: desglose por temperatura de almacenamiento

Sirve para detectar si el modelo se apoya en un atajo

Modelo	Grupo	n	Accuracy	MAE
ResNet-50	T10 (10 °C)	1350	75,3 %	0,259
ResNet-50	T20 (20 °C)	466	75,1 %	0,249
ResNet-50	Tamb	446	71,8 %	0,285
ViT-S/16	T10 (10 °C)	1350	73,9 %	0,267
ViT-S/16	T20 (20 °C)	466	68,7 %	0,318
ViT-S/16	Tamb	446	71,1 %	0,291
Híbrido: fusión tardía	T10 (10 °C)	1350	77,7 %	0,231
Híbrido: fusión tardía	T20 (20 °C)	466	76,2 %	0,240
Híbrido: fusión tardía	Tamb	446	74,4 %	0,256
ViT-Hybrid R26+S/32	T10 (10 °C)	1350	77,7 %	0,227
ViT-Hybrid R26+S/32	T20 (20 °C)	466	75,8 %	0,247
ViT-Hybrid R26+S/32	Tamb	446	72,0 %	0,280