

Clasificación del estado de madurez de paltas Hass

ResNet-50, ViT-S/16 e híbridos con presupuesto equiparado

Cristóbal Martínez ■ Entrega final, 23 de noviembre de 2026

14.710 fotografías, 478 frutas, índice ordinal de 5 niveles

El problema

Por qué importa acá y no solo en el paper

- Chile es uno de los mayores exportadores de palta Hass del mundo.
- La clasificación por madurez se hace hoy a ojo y al tacto, operario por operario, sin criterio homogéneo ni trazabilidad.
- Fruta verde en góndola: el consumidor la descarta. Fruta pasada en tránsito: pérdida total. Los dos errores cuestan.
- La tarea es **ordinal**, no categórica: $1 < 2 < 3 < 4 < 5$.
- Confundir un 1 con un 2 es un error de un día. Confundir un 1 con un 5 es mandar fruta podrida a la venta.

Índ.	Estado	Decisión
1	Verde	Dejar madurar
2	Iniciando	Lista en 2–3 días
3	Maduro I	Venta inmediata
4	Maduro II	Último día
5	Sobremaduro	Fuera de punto

La métrica tiene que castigar más los errores lejanos. La accuracy plana no lo hace: por eso usamos QWK.

Datos y limitaciones

Hass Avocado Ripening Photographic Dataset, Mendeley, CC BY 4.0

Imágenes

14.710

Frutas

478

Train/val/test

334/72/72

Licencia

CC BY 4.0



- **Fuga longitudinal: resuelta.**
- 6.871 pares de días consecutivos de la misma fruta. Partimos frutas, no imágenes, con un assert que falla si una fruta aparece en dos particiones.
- **Domain gap laboratorio → terreno: no resuelta, declarada.**
- Fondo blanco uniforme, una sola fruta centrada, iluminación difusa controlada, distancia fija. Una foto de celular en una feria está fuera de distribución. Es la limitación que decide si esto sirve en un packing o solo en un paper.
- **Un lote, una cosecha, un cultivar, etiquetas subjetivas.**
- 478 frutas portuguesas de 2022, solo Hass, etiquetado visual sin acuerdo inter-evaluador reportado: no conocemos el techo humano de esta tarea.

Detalle completo en la data card ([entregables/final/data_card.md](#)).

Las dos redes, en una imagen

La diferencia es CÓMO miran la foto

ResNet-50 · una lupa que recorre la fruta ViT-S/16 · un rompecabezas que conversa



- Va de a pedacitos y reutiliza el mismo detector en toda la foto (*convolución*).
- Buena para detalles: manchas, arrugas, tono.

- Parte la foto en 196 cuadraditos y los compara todos contra todos (*auto-atención*).
- Buena para relacionar zonas distantes.

Ninguna se programó desde cero: las dos vienen de timm, la biblioteca estándar de modelos de visión.

Por qué entrenan tan distinto

Todo se explica por lo que cada red ya sabe antes de empezar

ResNet-50 trae dos reglas de fábrica

- Lo que importa está **cerca**
- **No importa** en qué parte de la foto esté

Una mancha café es una mancha café, arriba o abajo de la fruta.

Eso no lo aprende: ya lo trae.

ViT-S/16 no trae ninguna

- Todos los cuadraditos le parecen **iguales**
- Ni siquiera sabe cuáles son **vecinos**

Tiene que deducir de los ejemplos hasta la noción de «al lado».

- El ViT necesita muchísimos más ejemplos.
- La ResNet arranca sabiendo mirar imágenes; el ViT tiene que descubrir primero *cómo* se mira una imagen, y recién después aprender de paltas.
- Por eso los dos parten desde ImageNet.
- Antes de ver una sola palta ya vieron 1,3 millones de fotos de cosas cotidianas. Ahí el ViT compensa: llega con el oficio aprendido.
- Y por eso el ViT es más delicado de entrenar.
- Entrenar es bajar un cerro a ciegas y el *learning rate* es el tamaño del paso. La ResNet aguanta pasos grandes; el ViT se cae.

Los dos híbridos

Dos formas distintas de juntar ambas ideas

1. Fusión tardía

- Las dos redes miran la misma foto por separado y al final se juntan sus dos opiniones para decidir.
- Como pedir una segunda opinión médica.
- Es el único modelo que escribimos nosotros (`src/paltas/models.py`).
- **Cuesta el doble: corre las dos redes enteras.**

2. ViT-Hybrid R26+S/32

- Una sola red: la parte convolucional procesa la foto primero y le entrega el resultado al transformer.
- En vez de dos opiniones, es una cadena de montaje.
- Es la arquitectura del paper original de ViT.
- **Tiene ventaja: más parámetros y más pre-entrenamiento.**

| Ninguno de los dos es equiparable a los baselines, y hay que decirlo: van como referencia, no como competidores.

Cómo hacemos que la comparación sea justa

Igualar tres cosas, no solo el tamaño

Eje igualado	ResNet-50	ViT-S/16 (DeiT-S)	Diferencia
Parámetros	23,52 M	21,67 M	7,9 %
GFLOPs @ 224 px	8,17	8,48	3,6 %
Pre-entrenamiento	ImageNet-1k	ImageNet-1k	ninguna

- Si una red es más grande y gana, no aprendimos nada: ganó por grande.
- Por eso igualamos el tamaño (parámetros), el trabajo que hace por foto (GFLOPs) y — lo que casi nadie iguala — **cuántas fotos vio antes**.
- El tercer punto es el que más distorsiona.
- El ViT que usa todo el mundo viene entrenado con 14 millones de fotos; la ResNet, con 1,3 millones. Comparándolos así estaríamos midiendo quién estudió más, no qué arquitectura es mejor.
- Usamos una versión del ViT llamada **DeiT-S**: es exactamente la misma red, pero entrenada con las mismas 1,3 millones de fotos que la ResNet. Ahí sí la comparación es limpia.

Como comparar dos atletas: sirve si entrenaron lo mismo y compiten en la misma categoría de peso.

Cómo las entrenamos

Todo igual para las dos, salvo lo que tiene que cambiar

Idéntico para ambas

- Las mismas fotos, en el mismo orden
- Las mismas deformaciones de las fotos
- La misma cantidad de vueltas al dataset
- El mismo criterio para elegir el mejor modelo
- El mismo criterio para cortar el entrenamiento

Distinto en el ViT

- **Pasos 3 veces más chicos.**
- Con pasos grandes el ViT se desestabiliza y deja de aprender.
- **Arranque más lento (*warmup*).**
- Las primeras vueltas van a media máquina para que no se rompa.

Un detalle que suele hacerse mal: en casi cualquier otra tarea conviene alterar mucho los colores de las fotos de entrenamiento, para que el modelo no dependa del color. Acá el color es la respuesta: si alteramos mucho el tono, una palta clase 2 se vuelve idéntica a una clase 4 pero con la etiqueta vieja. Le estaríamos enseñando mal. Por eso el color casi no se toca; girar y recortar la foto, en cambio, sí.

■ Igualar el learning rate «por justicia» no sería más justo: sería solo peor para el ViT.

01 Resultados

Tabla comparativa completa

Test: 2.262 imágenes de 72 frutas nunca vistas


Modelo	Params	GFLOPs	QWK	Accuracy	Macro-F1	MAE	Acc. ± 1	min
ResNet-50	23,5 M	8,2	0,936	74,6 %	0,735	0,262	99,2 %	10
ViT-S/16	21,7 M	8,5	0,931	72,2 %	0,711	0,282	99,5 %	5
ResNet-50 (scratch)	23,5 M	8,2	0,915	67,2 %	0,655	0,352	97,7 %	18
ViT-S/16 (scratch)	21,7 M	8,5	0,889	61,2 %	0,579	0,409	98,1 %	6
Híbrido: fusión tardía	46,4 M	16,7	0,941	76,7 %	0,760	0,238	99,5 %	4
ViT-Hybrid R26+S/32	36,0 M	6,9	0,941	76,2 %	0,752	0,242	99,6 %	15

Fila destacada: mejor QWK. El ViT-Hybrid R26 usa pesos de ImageNet-21k y más parámetros: es cota superior de referencia, no competidor equiparable.

ResNet frente a ViT: la comparación, no solo el número final

Todas las diferencias contra ResNet-50, bootstrap pareado agrupado por fruta

Los errores se concentran en la diagonal vecina: el modelo confunde estados adyacentes, no extremos




- ViT-S/16: $\Delta QWK = -0,0042$, IC 95 % $[-0,0095, +0,0006]$, $p = 0,095 \rightarrow$ **NO significativa**
- ResNet-50 (scratch): $\Delta QWK = -0,0203$, IC 95 % $[-0,0283, -0,0123]$, $p = 0,000 \rightarrow$ **significativa**
- ViT-S/16 (scratch): $\Delta QWK = -0,0465$, IC 95 % $[-0,0692, -0,0316]$, $p = 0,000 \rightarrow$ **significativa**
- Híbrido: fusión tardía: $\Delta QWK = +0,0055$, IC 95 % $[+0,0021, +0,0087]$, $p = 0,001 \rightarrow$ **significativa**
- ViT-Hybrid R26+S/32: $\Delta QWK = +0,0055$, IC 95 % $[+0,0005, +0,0104]$, $p = 0,031 \rightarrow$ **significativa**
- Todas las matrices son bandeadas: los errores de distancia ≥ 2 son casi inexistentes. Ningún modelo confunde una palta verde con una sobremadura.
- El cuello de botella son las clases intermedias (2, 3 y 4), donde la frontera es un corte continuo y las etiquetas son más subjetivas.

El experimento que lo demuestra

Reentrenamos las dos redes SIN ImageNet, solo con las fotos de paltas

Si le quitas ImageNet, el ViT se cae mucho más que la ResNet



- El ViT pierde $2,1\times$ más QWK y $1,5\times$ más accuracy que la ResNet.
- Es lo que predice la idea de las «reglas de fábrica»: la ResNet ya sabía mirar imágenes, el ViT tenía que aprenderlo, y 10.208 fotos de paltas no alcanzan para eso.
- Las cuatro caídas son estadísticamente sólidas ($p < 0,0001$), y cada red se compara contra *su propia* versión con ImageNet.

Con ImageNet las dos empatan. Sin ImageNet, no. La diferencia real entre ellas no es el techo, es cuántos datos necesitan para llegar.

Y hay una segunda razón

Esta tarea juega en la cancha de la convolución

- **El estado de madurez se lee en detalles pequeños y locales.**
- El color de la cáscara, las manchas, el arrugamiento. Todo eso está repartido por la superficie de la fruta y se ve de cerca.
- **Justo lo que la ResNet hace bien con su lupa.**
- La gran ventaja del ViT es relacionar zonas lejanas de una imagen. Acá no hay nada lejano que relacionar: todas las paltas tienen la misma forma, están centradas y sobre el mismo fondo.
- **Por eso el empate no es casualidad.**
- En un problema donde importara la composición global de la escena, probablemente el ViT sacaría ventaja. En este, su superpoder no suma.

■ Conclusión honesta: no es que el ViT sea peor, es que este problema no le pide lo que él hace mejor.

Los híbridos

¿Suma combinar ambos enfoques?

Híbrido: fusión tardía

QWK 0,941


ViT-Hybrid R26+S/32

QWK 0,941

- Híbrido: fusión tardía: 46,4 M params, 16,7 GFLOPs, acc 76,7 %
- ViT-Hybrid R26+S/32: 36,0 M params, 6,9 GFLOPs, acc 76,2 %


- En su tabla de desacuerdo, fusión y ResNet fallan *a la vez* en 20,6 % de las imágenes: más que el 18,0 % del par ResNet/ViT. La fusión no elimina los casos difíciles, los absorbe.
- La fusión tardía cuesta el doble de cómputo por imagen.
- Dos backbones completos en el forward. La pregunta no es si mejora, sino si mejora lo suficiente para justificar $2\times$ de latencia.
- Alcanza su mejor checkpoint en la **época 2** (3,5 min) con los backbones congelados: las representaciones ya contenían la información, lo que faltaba era combinarlas.

Costo computacional frente a desempeño



Dónde mira cada arquitectura

Grad-CAM en la ResNet, attention rollout en el ViT



- No usamos la misma técnica en ambos a propósito: Grad-CAM necesita un mapa de activaciones con estructura espacial, y en un ViT ese mapa es una secuencia de tokens que produce resultados ruidosos.
- Attention rollout acumula las matrices de atención de todas las capas para estimar cuánto aporta cada parche al token CLS.
- La ResNet se activa sobre texturas locales: manchas, arrugas, zonas oscuras.
- El ViT reparte la atención sobre regiones más extensas.
- En varios casos de desacuerdo, el Grad-CAM de la ResNet se activa sobre el *fondo*, fuera de la fruta, y son justamente esos los casos en que se equivoca.

Decisión: velocidad frente a precisión

Qué modelo llevaríamos a una línea de empaque

Modelo	QWK	Δ QWK	GFLOPs	Costo rel.	Veredicto
ResNet-50	0,9356	—	8,17	1,00×	Referencia. La recomendación operativa.
ViT-S/16	0,9313	−0,0042	8,48	1,04×	Empata en QWK al mismo costo y converge 2× más rápido.
Híbrido: fusión tardía	0,9410	+0,0055	16,66	2,04×	Mejora real pero marginal por 2× de cómputo.
ViT-Hybrid R26+S/32	0,9411	+0,0055	6,88	0,84×	Mejor QWK y más barato, pero con ventaja de ImageNet-21k.

- El criterio no es el QWK máximo, es el QWK por unidad de cómputo.
- En un packing la inferencia corre sobre miles de frutas por hora, probablemente en un equipo sin GPU dedicada.
- Una diferencia de QWK que no es estadísticamente significativa no justifica duplicar el cómputo: si los intervalos se solapan, gana el modelo más barato.
- Con accuracy ± 1 clase por sobre el 99 %, el error residual está dentro del ruido de etiquetado humano. Optimizar más el modelo no es donde está el retorno; cerrar el domain gap sí.

Demo

Gradio, casos nuevos del conjunto de test

- **Selección de modelo, distribución de probabilidad sobre las 5 clases y recomendación operativa.**
- Muestra además el mapa de atención del modelo: la demo no es una caja negra.
- Reporta el índice esperado (promedio ponderado), más informativo que el `argmax` cuando el modelo duda entre estados adyacentes.
- Avisa explícitamente cuando la confianza es baja y conviene revisión humana.
- **Los ejemplos precargados salen solo del conjunto de test: son frutas que ningún modelo vio durante el entrenamiento.**
- Advierte en pantalla sobre el domain gap.

`python app/gradio_app.py → http://localhost:7860`

Conclusiones y trabajo futuro

Qué aprendimos y qué sigue

- **Con presupuesto y pre-entrenamiento equiparados, las dos arquitecturas resuelven esta tarea a un nivel comparable.**
- La diferencia relevante no está entre CNN y transformer, sino entre tener o no tener pre-entrenamiento: ahí sí se separan, y de forma asimétrica.
- **El techo de esta tarea lo pone el etiquetado, no la arquitectura.**
- Sin acuerdo inter-evaluador reportado no sabemos cuánto del error residual es del modelo y cuánto es ruido de la etiqueta.
- **Trabajo futuro, en orden de retorno esperado:**
 - 1) Recolectar fotos de celular en condiciones reales chilenas y medir la caída. 2) Pérdida ordinal explícita (CORAL) en vez de entropía cruzada plana. 3) Predicción de vida útil restante en días, que es la pregunta que de verdad importa en la cadena de frío.

 github.com/cmartinez1524/clasificacion-de-paltas